ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA (ICAI)

MÁSTER EN TECNOLOGÍAS DE TELECOMUNICACIÓN

ANEXO B

"Adaptación del modelo Multitask-Stockformer al mercado estadounidense (S&P 500) y desarrollo de una interfaz interactiva para selección y backtesting de carteras"

Autor: Gonzalo Alonso Lidón

Director: David Martin Corral Calvo

Madrid

Enero 2025

Capítulo 1. INTRODUCCIÓN

En el ámbito de las finanzas cuantitativas, la selección de acciones para componer carteras óptimas es un problema complejo debido a la naturaleza no lineal y volátil de los mercados bursátiles. Tradicionalmente se han empleado modelos estadísticos (p.ej., ARIMA, GARCH) y factores financieros predefinidos (como indicadores técnicos o fundamentales) para predecir rendimientos. Sin embargo, dichos enfoques presentan limitaciones al enfrentar grandes volúmenes de datos y dinámicas de mercado cambiantes. En años recientes, los avances en aprendizaje profundo (***deep learning***) han permitido abordar la predicción de mercados con modelos capaces de extraer patrones complejos de series temporales de precios y volúmenes. Modelos basados en redes neuronales recurrentes (RNN/LSTM) y más recientemente en *transformers* con mecanismos de atención han mostrado resultados prometedores al capturar relaciones temporales de largo alcance en los datos financieros (Park et al., 2022; Lim et al., 2021; Zhou et al., 2021). Además, técnicas de procesamiento de señales como la **transformada wavelet** se han incorporado para descomponer la serie de retornos en diferentes frecuencias, logrando separar tendencias de largo plazo de fluctuaciones de corto plazo y reduciendo el ruido en los datos (Ma et al., 2025).

En este contexto surge *Multitask-Stockformer*, un modelo de selección de acciones que combina factores técnicos precio-volumen, transformada wavelet discreta y redes de atención multitarea. El modelo original, propuesto por Ma et al. (2025), integra estas técnicas para predecir simultáneamente el rendimiento futuro de una acción y su tendencia direccional (subida o bajada). Mediante la descomposición *wavelet*, Stockformer capta patrones de diferentes escalas temporales (tanto fluctuaciones bruscas de corto plazo como tendencias globales), mientras que una arquitectura de atención auto-regresiva permite aprender dependencias complejas en las series temporales de precios y volúmenes. Adicionalmente, incorpora relaciones entre activos mediante *embeddings* de grafos, modelando la interconexión entre distintas acciones (por ejemplo, a través de correlaciones

de precios o pertenencia al mismo sector). Los resultados reportados con este modelo en mercados internacionales (particularmente la bolsa de China) demuestran una mejora significativa en estabilidad y precisión frente a métodos previos, incluso bajo condiciones de alta volatilidad.

El presente proyecto se enmarca en la adaptación de dicho modelo avanzado al **mercado estadounidense**, concretamente al universo de acciones del **índice S&P 500**, que agrupa las 500 empresas más representativas de Estados Unidos. Además, se plantea el desarrollo de una interfaz de usuario interactiva que permita la selección de carteras y el *backtesting* (evaluación retrospectiva) de las estrategias propuestas por el modelo. De este modo, el trabajo combina una faceta investigadora (validar y extender Stockformer en un nuevo entorno de datos) con una faceta práctica (crear una herramienta accesible para usuarios finales), sentando las bases para aplicar técnicas de ***deep learning*** en la toma de decisiones de inversión en mercados occidentales.

Capítulo 2. ESTADO DE LA CUESTIÓN

El uso de modelos de aprendizaje profundo (*deep learning*) para la selección de acciones ha cobrado gran interés en la última década. En los primeros trabajos, arquitecturas recurrentes como las redes LSTM se aplicaron para predecir tendencias bursátiles, superando a métodos tradicionales gracias a su **capacidad de capturar dependencias de largo plazo y patrones no lineales** (Park et al., 2022). Con el avance de la investigación, se exploraron modelos híbridos que combinan enfoques diversos, tales como redes convolucionales (CNN) para extraer características de las series temporales junto con mecanismos de atención que ajustan dinámicamente la relevancia de pasos previos en la serie de precios.

Recientemente se han introducido arquitecturas tipo *Transformer* en el ámbito financiero. Gracias al mecanismo de autoatención, estos modelos pueden **capturar dependencias de largo alcance sin las limitaciones de las RNN**. En particular, abordajes como el *Temporal Fusion Transformer* (TFT) y otros *transformers* especializados en series temporales han mostrado un desempeño sobresaliente en la predicción de movimientos de mercado (Lim et al., 2021; Zhou et al., 2021). Además, permiten integrar múltiples fuentes de información simultáneamente (series de precios, indicadores macroeconómicos, etc.), atendiendo a las características más relevantes en cada momento.

En paralelo, la **transformada wavelet discreta** (DWT) se ha utilizado para descomponer las series de retornos en componentes **de distinta frecuencia**, lo que ayuda a distinguir las tendencias estructurales de las fluctuaciones transitorias. Diversos estudios muestran que combinar wavelets con redes neuronales **mejora la precisión predictiva** (Ma et al., 2025), por lo que muchos modelos recientes incorporan módulos basados en wavelets en etapas de preprocesamiento para reducir ruido y capturar patrones locales.

Otra línea de evolución es el aprendizaje multitarea en finanzas, que entrena un modelo para múltiples objetivos relacionados de forma simultánea, aprovechando el conocimiento compartido para mejorar el rendimiento del modelo. En el caso de Stockformer, las dos

tareas consisten en predecir **el retorno futuro (regresión)** y la **dirección de la tendencia** (clasificación alcista o bajista) de cada acción, combinando ambas salidas en una puntuación de selección. Trabajos recientes han ampliado este enfoque añadiendo, por ejemplo, la predicción del **riesgo** (volatilidad) junto con el **retorno esperado** (Park et al., 2022), de modo que el modelo no solo identifica activos con alto potencial de retorno, sino que también considera la incertidumbre asociada, mejorando la estabilidad de la cartera.

Asimismo, se han incorporado modelos basados en **grafos** para capturar las relaciones entre empresas. Técnicas como las *Graph Neural Networks* (GNN) o los *embeddings* de grafos representan cada acción como un nodo conectado a otros según la correlación de precios, pertenencia al mismo sector, vínculos en la cadena de suministro u otras relaciones económicas (Feng et al., 2019; Kim et al., 2019). Incorporar estas dependencias permite al modelo comprender efectos de contagio o eventos que afectan simultáneamente a grupos de activos.

El modelo Multitask-Stockformer, propuesto por Ma et al. (2025), representa la **convergencia de muchas de estas tendencias**. Su arquitectura incluye: (1) un módulo de **transformada wavelet** para separar los componentes de **baja y alta frecuencia** de los retornos; (2) un codificador espaciotemporal dual que procesa en **paralelo la información filtrada en distintas escalas temporales**; (3) un mecanismo de autoatención multitarea que predice simultáneamente el **retorno continuo y la dirección del movimiento para cada activo**; y (4) la integración de información entre múltiples acciones mediante ***embeddings* de grafos basados en las correlaciones entre series (por ejemplo, aplicando Struc2Vec sobre la matriz de correlaciones de rendimientos)**. Los experimentos de sus autores mostraron que este enfoque supera a métodos existentes en diversos conjuntos de datos de mercados reales, obteniendo resultados robustos incluso bajo alta volatilidad. Asimismo, en pruebas de *backtesting* la estrategia basada en Stockformer mantuvo un rendimiento estable y menores caídas máximas frente a estrategias clásicas, evidenciando su capacidad de adaptarse a distintas condiciones de mercado (Ma et al., 2025).

Capítulo 3. MOTIVACIÓN

La motivación principal de este proyecto es adaptar el modelo avanzado de selección de acciones Multitask-Stockformer al **mercado estadounidense**, dada la importancia global del índice S&P 500, con el fin de validar su eficacia y capacidad de **generalización** en un universo amplio de títulos. Paralelamente, se busca facilitar el uso de esta herramienta a través de una interfaz de usuario interactiva y accesible, que permita a analistas e inversores aplicar el modelo y analizar resultados de *backtesting* sin necesidad de profundos conocimientos técnicos. En conjunto, el proyecto se justifica tanto por el valor de extender el modelo a un nuevo contexto de mercado como por la utilidad de brindar una plataforma práctica que acerque dicha tecnología a usuarios finales.

Capítulo 4. OBJETIVOS

Los objetivos principales de este Trabajo de Fin de Máster se enuncian a continuación, abarcando tanto los aspectos de investigación como de desarrollo práctico. Se listan entre tres y cinco objetivos específicos, cada uno con su correspondiente explicación:

1. *Estudiar en profundidad el modelo original Multitask-Stockformer:*

Comprender la arquitectura y funcionamiento del modelo existente, analizando su código y documentación. Esto incluye familiarizarse con los **factores precio-volumen** empleados (360 indicadores técnicos en el caso original), el pipeline de **preprocesamiento de datos**, los detalles del entrenamiento multitarea y el procedimiento de *backtesting* utilizado. Este objetivo busca sentar una base sólida de conocimiento para poder replicar y modificar el modelo con confianza en el nuevo contexto.

2. *Adaptar el modelo y el pipeline de datos al universo S&P 500*

Diseñar y ejecutar las modificaciones necesarias para aplicar *Stockformer* a las 500 acciones del índice estadounidense. Implica **recolectar y preparar los datos históricos** de precios y volúmenes de todas estas empresas, así como **construir un conjunto de factores análogo** al del trabajo original (por ejemplo, calculando para cada acción indicadores técnicos similares a los usados originalmente, adaptados si es necesario al entorno americano). También supone ajustar cualquier hiperparámetro o componente del modelo que dependa de las características del mercado (frecuencia de datos, volatilidad típica, etc.). El resultado de este objetivo será un modelo entrenable con datos del S&P 500, listo para evaluar.

3. *Entrenar y evaluar el modelo adaptado comparándolo con benchmarks*

Realizar el **entrenamiento del modelo adaptado** usando datos históricos del S&P 500 (dividiendo en periodos de entrenamiento, validación y prueba, siguiendo buenas prácticas de *backtesting* para evitar sobreajuste temporal). Tras el entrenamiento, se evaluará el desempeño del modelo en selecciones de acciones futuras, comparando sus resultados con estrategias de referencia (*benchmarks*). Entre los benchmarks se incluirán, al menos, una estrategia pasiva de **buy-and-hold** sobre el índice S&P 500 (como proxy del mercado general) y quizás algún modelo simple basado en factores tradicionales (por ejemplo, seleccionar acciones por momentum o por volumen).

Se emplearán **métricas de *backtesting*** para la comparación, tales como la **rentabilidad acumulada** de la cartera seleccionada por el modelo, la **ratio de Sharpe** (rendimiento ajustado por riesgo) y el **máximo *drawdown*** (la mayor caída desde un pico). El objetivo es verificar si el modelo adaptado aporta valor añadido (mayor retorno o menor riesgo) frente a estrategias simples, y analizar en qué condiciones funciona mejor o peor.

4. *Desarrollar una interfaz de usuario interactiva para el modelo*

Implementar una web que permita a un usuario interactuar con el modelo sin necesidad de manejar código. Esta interfaz debe incluir funcionalidad para **seleccionar un rango de fechas** y otros parámetros de simulación, ejecutar el modelo *Stockformer* entrenado para obtener una **propuesta de cartera** (por ejemplo, top N acciones recomendadas), y mostrar los **resultados del *backtesting*** de esa selección de forma gráfica y numérica.

Se buscará que la interfaz sea intuitiva, mostrando gráficos de la evolución de la cartera vs. el índice, tablas con métricas (rentabilidad, Sharpe, drawdown, etc.), y posiblemente permitiendo inspeccionar qué factores o señales han influido en la selección (con fines explicativos). Este objetivo asegurará que el trabajo tenga un producto tangible y fácil de usar, demostrando la aplicabilidad real del modelo.

Capítulo 5. METODOLOGÍA

Para alcanzar los objetivos propuestos se seguirá una metodología estructurada en fases, combinando actividades de investigación, implementación y validación. A continuación, se describen dichas fases y su cronograma tentativo.

5.1 CRONOLOGÍA

- *Fase 1: Estudio del modelo original (Mes 1).*

Se revisará exhaustivamente el **repositorio** público de Multitask-Stockformer y, en lo posible, se **ejecutará el código original en un entorno controlado** para reproducir sus resultados en el contexto original (mercado chino). Se analizará detalladamente la arquitectura del modelo (capas de la red, entradas y salidas de datos) y el funcionamiento de sus principales componentes (módulo wavelet, codificador de doble frecuencia, mecanismo de atención multitarea y generación de la señal de selección). También se revisarán los **factores técnicos empleados en el modelo y su significado financiero**. Esta fase permitirá establecer una línea base de rendimiento y anticipar posibles desafíos técnicos antes de la adaptación a un nuevo mercado.

- *Fase 2: Preparación de datos del S&P 500 (Mes 2).*

Una vez analizado el modelo original, se recopilarán los datos históricos de precios y volúmenes de las acciones del S&P 500. Se establecerá un **horizonte temporal adecuado** (por ejemplo, 5–10 años de datos diarios) que cubra distintos ciclos de mercado. Los datos, obtenidos de fuentes públicas fiables, se almacenarán en el formato requerido. Luego se calcularán los **factores técnico-cuantitativos utilizados en el modelo original** (p. ej., medias móviles, volatilidad, volumen, momentum) para cada activo. Con todo ello, se construirá un conjunto de datos final dividido en entrenamiento, validación y prueba, respetando el orden temporal de las observaciones.

- *Fase 3: Adaptación y entrenamiento del modelo (Meses 3–4).*

Con los datos listos, se adaptará el código de Stockformer para aplicarlo al universo S&P 500, realizando ajustes en las dimensiones de entrada y en el módulo de relaciones entre activos si es necesario. A continuación, se entrenará el modelo utilizando recursos computacionales adecuados, monitorizando el proceso mediante las funciones de pérdida de las dos tareas (retorno y dirección) y ajustando hiperparámetros según convenga. Tras el entrenamiento, se **evaluará el modelo mediante *backtesting*, comparando el rendimiento de las carteras obtenidas con *benchmarks* relevantes** (por ejemplo, el índice S&P 500). Este análisis considerará métricas como la rentabilidad acumulada, la ratio de Sharpe o el máximo *drawdown*, complementadas con una evaluación cualitativa del comportamiento del modelo en distintos escenarios de mercado.

- *Fase 4: Desarrollo de la interfaz web (Meses 4–5).*

En paralelo al entrenamiento, se desarrollará una **interfaz de usuario interactiva para facilitar el uso del modelo**. Se considerarán tecnologías de fácil integración con Python (p. ej., Streamlit o Dash) que prioricen la simplicidad y claridad de uso. La interfaz permitirá configurar parámetros, ejecutar el modelo y visualizar los resultados del *backtesting* mediante gráficos y tablas. El objetivo es obtener un prototipo funcional que acerque el modelo a usuarios no expertos y refuerce el carácter aplicado del proyecto.

- *Fase 5: Documentación y cierre (Mes 6).*

En esta fase final se elaborará la memoria del proyecto, documentando la arquitectura adaptada, las decisiones de diseño adoptadas y los resultados obtenidos. Asimismo, se realizará un análisis crítico del desempeño del modelo en el nuevo mercado, identificando limitaciones y proponiendo posibles mejoras futuras. Tras la revisión del documento por el director, se preparará la defensa del trabajo.

Este cronograma es orientativo y podría ajustarse según la evolución del proyecto. En todo caso, refleja una secuencia lógica que inicia con el estudio del modelo original, continúa con su adaptación y validación en el nuevo mercado, y culmina con el desarrollo de la herramienta práctica y la comunicación de los resultados obtenidos.

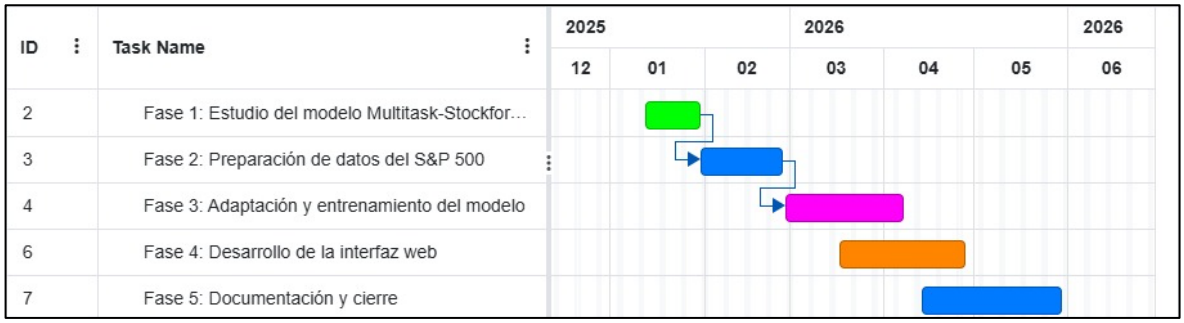

Ilustración 1: Diagrama Gantt de la Cronología del Proyecto

5.2 PIPELINE DE PROCESAMIENTO DE DATOS Y MODELADO

El proyecto se apoya en un pipeline modular de procesamiento de datos y modelado, alineado con las fases del cronograma y diseñado para facilitar tanto la adaptación del modelo al S&P 500 como su evaluación mediante *backtesting*.

El flujo de trabajo se estructura en las siguientes etapas principales:

- Fuente de datos: precios y volúmenes históricos de las acciones del S&P 500 (frecuencia diaria).
- Preprocesamiento: limpieza de datos, cálculo de factores técnico-cuantitativos precio–volumen y descomposición mediante transformada wavelet.
- Construcción de datasets: división temporal en conjuntos de entrenamiento, validación y prueba.
- Modelo Multitask-Stockformer: entrenamiento del modelo multitarea para predicción de retorno y dirección, incorporando relaciones entre activos.
- Selección de cartera: generación de un ranking y selección de las acciones top-N.
- Backtesting y evaluación: simulación histórica y cálculo de métricas de rendimiento (rentabilidad, ratio de Sharpe y drawdown).
- Interfaz web: visualización interactiva de resultados y configuración de parámetros.

Capítulo 6. RECURSOS

Para la realización del proyecto se cuentan únicamente con los recursos clave, eliminando detalles accesorios y garantizando su disponibilidad:

- Modelo original: Código fuente del Multitask-Stockformer original, disponible en su repositorio público (por ejemplo, en GitHub), que sirve de base para la adaptación.
- Datos del S&P 500: Conjunto de datos histórico de precios y volúmenes de las acciones que componen el índice S&P 500, necesario para calcular los factores y alimentar el modelo adaptado.
- Herramientas de desarrollo: Entorno de programación en Python, junto con librerías de machine learning (p. ej., PyTorch) para implementar y entrenar el modelo, y frameworks adecuados para el desarrollo de la interfaz de usuario (por ejemplo, bibliotecas para aplicaciones web interactivas).
- Recursos computacionales: Equipamiento o servicio de cómputo con la capacidad suficiente (CPU y, de ser posible, GPU) para entrenar el modelo con el volumen de datos del S&P 500 y para ejecutar la aplicación interactiva de manera fluida.

Capítulo 7. BIBLIOGRAFÍA

Feng, F., He, X., Wang, X., Luo, C., Liu, Y., & Chua, T.-S. (2019).
Temporal relational ranking for stock prediction. *ACM Transactions on Information Systems, 37*(2), Article 40.
https://doi.org/10.1145/3309547

Kim, R., So, C. H., Jeong, M., Lee, S., Kim, J., & Kang, J. (2019).
HATS: A hierarchical graph attention network for stock movement prediction. *arXiv:1908.07999*.
https://arxiv.org/abs/1908.07999

Lim, B., Arik, S. Ö., Loeff, N., & Pfister, T. (2021).
Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting, 37*(4), 1748–1764.
https://doi.org/10.1016/j.ijforecast.2021.03.012

Ma, B., Xue, Y., Lu, Y., & Chen, J. (2025).
Stockformer: A price–volume factor stock selection model based on wavelet transform and multi-task self-attention networks. *Expert Systems with Applications, 273*, 126803.
https://doi.org/10.1016/j.eswa.2025.126803

Park, H. J., Kim, Y., & Kim, H. Y. (2022).
Stock market forecasting using a multi-task approach integrating long short-term memory and the random forest framework. *Applied Soft Computing, 114*, 108106.
https://doi.org/10.1016/j.asoc.2021.108106

Sharpe, W. F. (1994).

The Sharpe ratio. *The Journal of Portfolio Management, 21*(1), 49–58. https://doi.org/10.3905/jpm.1994.409501

Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., & Zhang, W. (2021).

Informer: Beyond efficient transformer for long sequence time-series forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence, 35*(12), 11106–11115.