



Universidad Pontificia Comillas, ICAI
Máster Universitario en Ingeniería de Telecomunicación

Trabajo Fin de Máster

Parsimonia frente a Stockformer en el S&P 500: transferencia fallida y dónde reside el retorno

Autor: Gonzalo Alonso Lidón

Dirigido por: David Martín-Corral Calvo

Madrid, junio de 2026

Resumen

El *deep learning* es hoy la herramienta dominante en la predicción bursátil, pero casi nunca se comprueba si la capacidad predictiva de un modelo afinado en un mercado se mantiene al trasladarlo a otro estructuralmente distinto. Esta tesis estudia esa transferencia *cross-market* de un modelo de *deep learning* financiero, en dos partes. La primera evalúa si Stockformer (una arquitectura de en torno a un millón de parámetros, basada en *wavelets*, *transformers* y grafos, calibrada sobre acciones chinas A-shares) traslada su poder predictivo al S&P 500, evaluado a horizonte diario mediante el coeficiente de información (*rank IC*) transversal; la estrategia de explotación de la Parte II opera después a frecuencia semanal. Para ello se sitúa al modelo dentro de una *complexity ladder* que lo compara con modelos más simples, bajo un mismo *harness* de evaluación y una auditoría anti-fuga (*leakage*) cuyo único hallazgo es una fuga deliberada a favor del modelo complejo. El veredicto es negativo. Stockformer no transfiere (su coeficiente de información *out-of-sample* cae a $\approx -0,003$, indistinguible de cero, lejos de los IC del orden de 0,06 propios de su mercado de origen) y un Lasso de apenas cinco coeficientes lo supera en IC (+0,0238), una ventaja direccional que no alcanza la significancia estadística al 5 %. El fallo está sobredeterminado, porque los modos de fallo se acumulan y ninguna corrección aislada de la arquitectura recupera la señal.

La segunda parte pregunta qué genera el retorno neto. Una atribución etapa a etapa muestra que el Sharpe neto depende de la construcción de cartera *cost-aware*. La señal débil (IC semanal $\approx 0,003$) genera un retorno bruto que los costes destruyen; es la construcción la que lo *preserva* en neto, y no la que lo crea de la nada. Una búsqueda disciplinada de señal precisa la respuesta. El reversal y los fundamentales no aportan, pero el momentum residual, un factor simple con contenido, combinado con esa construcción eleva el Sharpe neto robusto a 0,72 ($t = 1,82$) sobre un *walk-forward* de 311 semanas, frente al 0,38 de la base sobre la misma ventana. El resultado se reporta con cautela. Ningún candidato cruza el listón pre-registrado ($t_{NW} > 2$ y *holdout* > 0); el momentum residual se queda en $t = 1,82$, de modo que la mejora, aunque apreciable, no es concluyente. Esa búsqueda de señal, validada en un *holdout* reservado, forma buena parte de la respuesta a la segunda pregunta. La contribución del trabajo es doble, empírica (evidencia de no transferibilidad *cross-market*) y metodológica, esto es, un *pipeline* reproducible que sitúa el origen del retorno en una señal-factor simple y en la construcción, no en la arquitectura.

Abstract

Deep learning is now the dominant tool in stock-return prediction, yet the predictive power of a model tuned on one market is seldom checked when it is moved to a structurally different one. This thesis studies that cross-market transfer of a financial deep-learning model in two parts. The first asks whether Stockformer (a roughly

one-million parameter wavelet-transformer-graph architecture calibrated on Chinese A-shares) carries its predictive power over to the S&P 500, evaluated at a daily horizon via the cross-sectional information coefficient (rank IC); the Part II trading strategy then operates at a weekly frequency. The model is placed inside a complexity ladder that compares it with simpler models, under a unified evaluation harness and an anti-leakage audit whose only finding is a leak deliberately kept in favour of the complex model. The verdict is negative. Stockformer does not transfer (its out-of-sample information coefficient falls to $\approx -0,003$, indistinguishable from zero) and a five-coefficient Lasso beats it in IC (+0,0238), a directional advantage that does not reach statistical significance at 5 %. The failure is overdetermined, since failure modes compound and no isolated architectural fix recovers the signal. The second part asks what generates net return. A stage-by-stage attribution shows that the net Sharpe depends on cost-aware portfolio construction. The weak signal (weekly IC $\approx 0,003$) produces a gross return that costs would erase; it is the construction that *preserves* it in net terms, and not the construction that creates it from nothing. A disciplined signal search sharpens the answer. Short-term reversal and fundamentals add nothing, but residual momentum, a simple factor with genuine content, combined with that construction raises the robust net Sharpe to 0,72 ($t = 1,82$) over a 311-week walk-forward, against 0,38 for the baseline on the same window. The result is reported with caution. No candidate clears the pre-registered bar ($t_{\text{NW}} > 2$ and $\text{holdout} > 0$); residual momentum stops at $t = 1,82$, so the improvement, though appreciable, is not conclusive. This signal search, validated on a held-out sample, is much of the answer to the second question. The contribution is twofold, empirical (evidence of cross-market non-transferability) and methodological, namely a reproducible pipeline that places the source of the return in a simple factor signal and in construction, rather than in architecture.

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Preguntas de investigación	2
1.3. Contribución	2
1.4. Organización del documento	3
2. Estado del arte	5
2.1. Eficiencia de mercado en China y EE.UU.	5
2.2. Ingeniería de variables para predicción bursátil	6
2.3. Arquitecturas de aprendizaje profundo	7
2.4. Descomposición de señal y wavelets	7
2.5. Modelado de relaciones entre acciones con grafos	8
2.6. Funciones de pérdida para ranking	8
2.7. Metodología de entrenamiento	9
2.8. Construcción y evaluación de cartera	9
3. Arquitectura original de Stockformer	11
3.1. Conjunto de variables Alpha360	11
3.2. Descomposición wavelet (DWT Sym2)	12
3.3. Encoder espacio-temporal de doble canal	12
3.4. Embeddings de grafo (struc2vec)	13
3.5. Cabezas multitarea	14
3.6. Configuración de entrenamiento	15
3.7. Resultados originales y supuestos de mercado	15
4. Metodología	17
4.1. El universo S&P 500 y el panel de datos	17
4.2. Ingeniería de variables	19
4.3. Harness de evaluación	20
4.4. La complexity ladder	21
4.5. Función de pérdida de ranking	22
4.6. Auditoría anti-leakage	23
5. Parte I: ¿Transfiere Stockformer?	25
5.1. Resultados de la complexity ladder	25
5.2. Significancia estadística	27
5.3. Modos de fallo de la transferencia	30

6. Parte II: ¿Qué sí funciona?	33
6.1. De la señal a las posiciones	33
6.2. Construcción de cartera cost-aware	34
6.3. Resultados	35
6.4. Robustez walk-forward	36
6.5. Atribución de construcción	37
6.6. Ablaciones de datos (Tier B/C)	39
6.7. Los límites de la construcción cost-aware	39
6.7.1. El espacio de construcción y la frontera de costes	40
6.7.2. ¿Se puede mejorar el libro simple? Dos pruebas pre-registradas .	41
6.7.3. El principio simpler-is-better en las dos capas	42
6.8. ¿Dónde reside el contenido predictivo de la señal?	42
6.8.1. Transferencia modular y banco ampliado	44
7. Discusión	47
7.1. Por qué los modelos simples ganan	47
7.2. El efecto compuesto de los modos de fallo	48
7.3. Honestidad sobre el Sharpe	49
7.4. Comparación con benchmarks reportados	51
7.5. Limitaciones	52
8. Conclusiones y trabajo futuro	55
8.1. Conclusiones	55
8.2. Trabajo futuro	56
8.3. Implicaciones	57
A. Tablas completas	59
A.1. Complexity ladder completa	59
A.2. Robustez con datos adicionales	59
A.3. Baseline simple de referencia	60
Bibliografía	61

Índice de figuras

5.1.	IC medio frente a número de parámetros (eje horizontal en escala logarítmica) a lo largo de la <i>complexity ladder</i> . Los controles de sanidad sin parámetros entrenables (<i>momentum</i> y <i>reversal</i> , 0 parámetros) se sitúan por convención en $x = 1$, el extremo izquierdo del eje, al no ser representable el cero en escala logarítmica. La relación es plana o decreciente: el IC no crece con la complejidad y el modelo más complejo (Stockformer) es el peor.	27
5.2.	IC medio por modelo con intervalos de confianza <i>bootstrap</i> . El intervalo de Stockformer solapa el cero, lo que es coherente con la ausencia de señal; los modelos simples presentan IC positivos, aunque sus intervalos también rozan el cero, coherente con la significancia marginal de los contrastes.	28
6.1.	Curva de retorno acumulado <i>out-of-sample</i> de la estrategia semanal <i>market-neutral</i> : serie bruta (gris) frente a serie neta de costes de 8 puntos básicos por lado (roja). La distancia creciente entre ambas curvas es el coste acumulado de la rotación, que la construcción <i>cost-aware</i> mantiene bajo control.	36
6.2.	Atribución de construcción: Sharpe neto de cada variante con su error estándar. La neutralización (segunda barra) <i>resta</i> Sharpe; la construcción <i>cost-aware</i> (tercera barra) es la etapa que recupera el resultado y lo lleva a territorio positivo. El alfa crudo del predictor es el mismo en las cuatro variantes; lo que cambia es la construcción de cartera.	38
6.3.	Espacio de construcción: Sharpe neto (con error estándar) frente a cada decisión de construcción sobre el <i>walk-forward</i> de 215 semanas. La línea vertical marca el valor por defecto. El Sharpe es invariante al objetivo de volatilidad (control de sanidad); el término de riesgo (último panel) no mejora el resultado.	40
6.4.	Retorno acumulado del <i>pipeline</i> momentum residual más <i>ensemble</i> sobre la construcción <i>cost-aware</i> (<i>walk-forward</i> de 311 semanas, del 27 de marzo de 2020 al 6 de marzo de 2026): serie bruta (gris) frente a serie neta de 8 bps por lado (verde). El Sharpe neto es de 0,72 ($t = 1,82$) e incluye el <i>momentum-crash</i> de 2021.	44

7.1. Mapa de calor de las métricas de la estrategia a través de las configuraciones de construcción y los protocolos de evaluación. El contraste entre la ventana favorable de 52 semanas y el <i>walk-forward</i> de 215 semanas muestra la fragilidad del Sharpe neto de 0,95 frente al estimador robusto de $0,58 \pm 0,49$	50
--	----

Índice de tablas

3.1. Configuración de entrenamiento del Stockformer en el S&P 500.	15
5.1. Complexity ladder: IC, parámetros y Sharpe por modelo (split único, test del 14 de marzo de 2025 al 12 de marzo de 2026). Todos los modelos se evalúan sobre esos 250 días salvo Stockformer, sobre los 236 días comunes a su corrida (que arranca el 3 de abril de 2025).	26
5.2. Tests de significancia del IC frente a Stockformer (diferencia de medias, t , p). El contraste usa los $n = 236$ días comunes a ambos modelos, por lo que ΔIC no coincide con la resta directa de los IC medios de la Tabla 5.1 (250 días); el <i>momentum</i> se incluye como control de cordura.	28
5.3. Contraste direccional del rank-IC diario frente a Stockformer (comparación pareada por día, n días comunes). Test de signos temporal (binomial exacto, dos colas), Wilcoxon, intervalo de confianza al 95 % de la diferencia media de IC (ΔIC) y efecto mínimo detectable (MDE) al 80 % de potencia. Ningún modelo cruza 0,05: la superioridad es direccional, no concluyente, y todos los ΔIC observados caen por debajo de su MDE.	29
6.1. Estrategia semanal market-neutral cost-aware (52 semanas, del 14 de marzo de 2025 al 6 de marzo de 2026).	35
6.2. Robustez walk-forward de la estrategia semanal (215 semanas OOS, de enero de 2022 a marzo de 2026).	36
6.3. Atribución de construcción: aporte incremental de cada etapa al Sharpe neto.	37
6.4. Sensibilidad del Sharpe neto (walk-forward, 215 semanas) al coste de transacción, manteniendo el resto de la construcción en su valor por defecto. El Sharpe neto cruza cero en torno a 20 bps/lado.	40
6.5. Blend constante frente a blend condicionado por régimen, sobre el mismo walk-forward de 215 semanas y la misma construcción <i>full</i> cost-aware. Peso del LightGBM por régimen (resto, ElasticNet): low = 0,0, normal = 0,0, high = 0,0. La diferencia de Sharpe es inferior a 1 SE; según el criterio de éxito pre-registrado ($> 1 SE$), el resultado es nulo.	41
6.6. Término de riesgo (covarianza Ledoit-Wolf) en el optimizador cost-aware: Sharpe neto y MaxDD por aversión al riesgo λ (walk-forward, 215 semanas). $\lambda = 0$ es el <i>baseline</i> . Resultado: no distinguible de cero ($< 1 SE$), por debajo del listón de éxito pre-registrado.	42

6.7.	Búsqueda de señal para RQ2 sobre la misma ventana <i>walk-forward</i> de 311 semanas (2020–2026, incluye el <i>momentum-crash</i> de 2021; <i>holdout</i> : últimas 104 semanas). Misma construcción <i>cost-aware</i> (coste 8 bps/lado) para todas las señales. El reversal no aporta ni en bruto (Sharpe bruto prácticamente nulo) y los fundamentales no aportan; el momentum residual es la única señal con IC e <i>holdout</i> positivos, y su combinación con el <i>ensemble</i> da el mejor Sharpe neto. La columna <i>Holdout</i> es el Sharpe neto anualizado sobre las 104 semanas reservadas. . . .	43
6.8.	Búsqueda de señal ampliada: señales destiladas de la arquitectura del Stockformer (su grafo en tres formas (correlación, lead-lag direccional y sector) y su wavelet en las dos bandas) y banco pre-registrado de factores establecidos, cada una <i>sola</i> y <i>combinada</i> con el <i>ensemble</i> de <i>features</i> (columnas +ens). Misma construcción <i>cost-aware</i> y <i>walk-forward</i> de 311 semanas (<i>holdout</i> : 104) que la Tabla 6.7. Las columnas <i>Hold.</i> son el Sharpe neto anualizado restringido a las 104 semanas de <i>holdout</i> . Listón pre-registrado: $t_{NW} > 2$ y <i>holdout</i> > 0.	45
A.1.	Resultados completos de la complexity ladder	59
A.2.	Robustez walk-forward con fundamentales (Tier B)	60
A.3.	Robustez walk-forward con realized-vol (Tier C)	60

Capítulo 1

Introducción

1.1. Motivación

En la última década el *deep learning* se ha vuelto la herramienta principal de la predicción bursátil. Frente a los modelos lineales clásicos del *asset pricing*, las arquitecturas profundas (redes recurrentes, *transformers*, descomposiciones en *wavelets* y grafos de relaciones entre acciones) tratan de capturar las dependencias no lineales y temporales que gobiernan la sección transversal de los retornos. La literatura reciente publica un flujo constante de arquitecturas que, sobre los mercados en que fueron concebidas, mejoran el coeficiente de información y el Sharpe de cartera. Stockformer, el modelo de Ma et al. [1] sobre el que se basa esta tesis, es un ejemplo de esa línea. Combina una transformada *wavelet* discreta, un codificador dual con auto-atención, *embeddings* de grafo de relaciones y un conjunto de cabezas multitarea, y da buenos resultados sobre los índices chinos CSI 300 y CSI 500.

Importar una arquitectura del estado del arte a un mercado nuevo resulta atractivo porque el coste de adopción parece bajo (reentrenar sobre datos locales, ajustar hiperparámetros) frente a la promesa de un retorno predictivo ya demostrado en otro sitio. El problema es que se da por hecho algo que casi nunca se comprueba: que la capacidad predictiva de un modelo se traslada de un mercado a otro. Los mercados financieros difieren en su microestructura, en su grado de eficiencia y en la composición de sus participantes. Un modelo afinado sobre acciones chinas A-shares (un universo minorista, con fricciones de negociación y patrones de *momentum* y *reversal* marcados) trabaja en un régimen estadístico muy distinto del de las *large-caps* estadounidenses, que están entre los segmentos más líquidos y eficientes del mundo. Si una arquitectura compleja conserva su poder predictivo al cruzar esa frontera es una pregunta empírica, y su respuesta tiene consecuencias directas para quien quiera construir una estrategia rentable sobre señales importadas.

Este trabajo aborda ese riesgo. Toma una arquitectura del estado del arte, calibrada y validada en un mercado, y pregunta si transfiere a otro estructuralmente distinto. Cuando la respuesta es negativa, pregunta además qué genera el retorno neto que sí sobrevive a los costes de transacción en el mercado de destino. La idea es poner el entusiasmo arquitectónico a prueba con datos, ver qué aporta la complejidad del modelo y qué no, y situar el origen del retorno donde lo indican los datos.

1.2. Preguntas de investigación

El trabajo se organiza en torno a dos preguntas de investigación encadenadas, que ordenan el cuerpo empírico de la memoria y a las que el Capítulo 8 responde de forma explícita.

RQ1. ¿Transfiere Stockformer, un modelo de *deep learning* financiero calibrado sobre acciones chinas A-shares, su capacidad predictiva al S&P 500? Es decir, ¿produce, sobre el universo *large-cap* estadounidense y a horizonte diario (el coeficiente de información *rank IC* transversal calculado día a día bajo un protocolo de evaluación riguroso), un valor *out-of-sample* positivo y estable, comparable o superior al de modelos sustancialmente más simples? La transferencia se contrasta a este horizonte diario, el de la *complexity ladder*; la estrategia de explotación de la Parte II opera después a frecuencia semanal.

RQ2. Si la capacidad del modelo no es la fuente del retorno, ¿qué genera realmente el retorno neto de costes en el S&P 500? La cuestión tiene dos caras. La primera es de *construcción*. Una vez fijada la señal, ¿qué etapa del *pipeline* aporta el Sharpe neto positivo, la calidad de la predicción, la neutralización factorial o la construcción de cartera consciente del coste? La segunda es de *señal*. ¿Añade algo una búsqueda disciplinada, montada sobre el predictor de *features* existente, que rastree señales simples con contenido propio, incluidas las destiladas del propio Stockformer? La primera toma la señal como dada y audita la mecánica que la convierte en retorno; la segunda mantiene fija esa mecánica y pregunta si una señal mejor aportaría más.

La segunda pregunta solo tiene sentido una vez respondida la primera, y por eso ambas se abordan de forma secuencial. La Parte I (Capítulo 5) responde a RQ1; la Parte II (Capítulo 6) responde a RQ2. La memoria sigue ese mismo orden: primero un resultado negativo y, a partir de él, una indagación constructiva.

1.3. Contribución

De las dos preguntas anteriores salen dos contribuciones, una por cada parte del cuerpo empírico.

La primera contribución es empírica y documenta la *no transferibilidad cross-market* de un modelo de *deep learning* financiero. Stockformer, una arquitectura de en torno a un millón de parámetros, no transfiere su capacidad predictiva al S&P 500. Su coeficiente de información *out-of-sample* cae a $\approx -0,003$, una correlación de rangos estadísticamente indistinguible de cero, y lo bate un Lasso de apenas cinco coeficientes que alcanza un IC de $+0,0238$. El fallo tampoco se debe a un defecto puntual de configuración. Como los modos de fallo se componen, no es plausible que ninguna corrección aislada (pérdida de *ranking*, grafos dinámicos, *features* enriquecidas o *walk-forward*) recupere la señal. Este resultado conecta con el fenómeno *shallow-beats-deep* que documenta Gu, Kelly y Xiu [2] y que Rahimikia y Poon [3] confirma en datos recientes, esto es, que la ganancia del *machine learning* en *asset pricing* procede antes de la regularización que de la profundidad arquitectónica.

La segunda contribución es metodológica y práctica, y es un *pipeline* reproducible que mide de dónde sale el Sharpe neto. La atribución etapa a etapa muestra que, con un IC semanal de la señal de apenas 0,0033, el retorno no procede del poder predictivo; la neutralización factorial por sí sola resta Sharpe, y es la construcción de cartera consciente del coste (*cost-aware*) la que recupera el resultado. Ese resultado se reporta con la cautela que el dato exige. El Sharpe neto de 0,95 medido sobre una ventana favorable de 52 semanas es un estimador de varianza muy alta; el estimador defendible, el del *walk-forward* sobre 215 semanas, es de $0,58 \pm 0,49$, no estadísticamente distinguible de cero. Una búsqueda disciplinada de señal afina la respuesta a RQ2. El momentum residual, un factor simple con contenido, combinado con esa construcción sube el Sharpe robusto a 0,72 ($t = 1,82$) sobre una ventana más larga de 311 semanas en la que la propia base cae a 0,38; la mejora es apreciable, aunque se queda al borde de la significancia. Esa búsqueda de señal está pre-registrada y validada en un *holdout* reservado. Complementa al predictor de *features* en vez de sustituirlo, y comprueba algo concreto: si las ideas de una arquitectura que no transfiere en bloque, reducidas a señales simples y causales, conservan algún valor en el mercado de destino.

La honestidad metodológica forma parte de la contribución. Todo el cuerpo empírico se apoya en una auditoría anti-fuga (*leakage*) que supera cinco verificaciones y, en la sexta, mete a propósito una fuga a favor del modelo complejo (el grafo de relaciones se construye sobre todo el histórico). Ese sesgo concedido juega *en contra* de la conclusión negativa y, aun así, esta se sostiene, lo que asegura que el IC negativo de Stockformer es genuino y no un artefacto. Los resultados negativos se reportan con la misma extensión y el mismo detalle que los positivos: las ablaciones de datos que no mejoran el Sharpe, la ventana favorable contrastada con el estimador robusto, la significancia económica que se reconoce como límite. La lección de fondo es una versión disciplinada del principio *simpler-is-better*. En el régimen más eficiente y arbitrado, la parsimonia del modelo es la respuesta correcta a una sección transversal estrecha, y el retorno que sobrevive a los costes viene de una señal-factor simple y de cómo se construye la cartera, no de cuánta capacidad tiene el predictor.

1.4. Organización del documento

El resto de la memoria se organiza como sigue. El Capítulo 2 revisa el estado del arte: la eficiencia comparada de los mercados chino y estadounidense, las familias de *features* y arquitecturas de *deep learning* para selección de acciones, las pérdidas de *ranking* y la metodología de construcción y evaluación de cartera, con especial atención a la evidencia *shallow-beats-deep*. El Capítulo 3 describe en detalle la arquitectura original de Stockformer y los supuestos de microestructura china a los que está ligada.

El Capítulo 4 presenta la metodología propia: el panel del S&P 500 y sus particiones con *walk-forward* purgado y embargado, el *feature engineering*, el *harness* de evaluación unificado, la *complexity ladder* que ordena los modelos por capacidad y la auditoría anti-fuga.

Los dos capítulos siguientes son el cuerpo empírico. El Capítulo 5 (Parte I) responde a RQ1 con la escalera de complejidad y asocia cada resultado a un modo de fallo documentado en la literatura. El Capítulo 6 (Parte II) responde a RQ2. Construye la estrategia semanal *market-neutral* consciente del coste, descompone el Sharpe neto por

etapa de construcción y reporta tanto la ventana favorable como el estimador robusto.

El Capítulo 7 discute por qué *simpler-is-better* en este régimen, el efecto compuesto de los modos de fallo y las limitaciones del estudio. Por último, el Capítulo 8 recoge las respuestas a las dos preguntas, resume las dos contribuciones y apunta las líneas de trabajo futuro, empezando por el flujo de inferencia *live* para la predicción de posiciones reales.

Capítulo 2

Estado del arte

Este capítulo revisa la literatura en la que se apoya la tesis central del trabajo. Esa tesis dice dos cosas. Primero, que un modelo de aprendizaje profundo diseñado y validado sobre el mercado chino (*Stockformer*) no traslada su capacidad predictiva al S&P 500. Segundo, que en ese mercado los modelos sencillos combinados con una construcción de cartera consciente de los costes baten a las arquitecturas complejas.

2.1. Eficiencia de mercado en China y EE.UU.

La hipótesis de mercado eficiente dice que los precios incorporan con rapidez la información disponible, de modo que la parte predecible de los retornos futuros tiende a cero. El grado de eficiencia no es igual en todos los mercados. La tesis parte de esa diferencia, porque un modelo calibrado donde la ineficiencia es alta puede no encontrar señal donde la ineficiencia es baja.

Los mercados de acciones *A* de China son un ejemplo claro de mercado con ineficiencias estructurales explotables. Hay tres rasgos microestructurales que lo explican. El primero es la composición del inversor. La mayoría del volumen viene de inversores minoristas (*retail*) que generan patrones predecibles en la sección cruzada de retornos (persecución de tendencias, sobre-reacción, operativa de corto plazo). El segundo son los límites diarios de precio (*price limits*, típicamente del $\pm 10\%$), que reparten la incorporación de información en varias sesiones y producen autocorrelaciones artificiales. El tercero son las restricciones a la venta en corto y a la participación extranjera, que impiden el arbitraje que normalmente borraría esos patrones.

Esta predecibilidad alta explica por qué la literatura sobre arquitecturas de modelos con *information coefficients* (IC) altos se ha desarrollado casi siempre sobre acciones *A* chinas. En esa línea, Li et al. [4] presentan *MASTER*, un *transformer* guiado por información de mercado y evaluado sobre los universos chinos CSI300 y CSI800; Fan y Shen [5] validan *StockMixer* sobre conjuntos que incluyen el mercado chino. El propio *Stockformer* [1] se diseña y ajusta sobre todo en ese entorno. Parte del IC que se reporta en este mercado puede deberse a supuestos de operativa difíciles de ejecutar en la práctica, como posiciones rentables en sesiones donde el precio alcanza el límite diario y la liquidez es escasa. Por eso un IC alto sobre el papel no siempre se traduce en un *Sharpe* neto que se pueda realizar.

El S&P 500 está en el extremo opuesto. Es un universo de gran capitalización, dominado por inversores institucionales, con venta en corto muy presente, costes de

transacción bajos y muchos arbitrajistas que borran con rapidez cualquier patrón sistemático. En este entorno, la señal cross-seccional que se puede explotar es débil frente a los costes. La consecuencia es que la predecibilidad es mucho menor y que cualquier ventaja predictiva tiene que sobrevivir a una estructura de costes realista para tener valor económico.

2.2. Ingeniería de variables para predicción bursátil

Si la arquitectura del modelo importa menos de lo que sugiere el aprendizaje profundo, entonces el conjunto de variables (*features*) pasa a ser el factor principal. La referencia principal es Gu, Kelly y Xiu [2], que plantean la valoración de activos como un problema de aprendizaje supervisado sobre un panel grande de acciones estadounidenses (cerca de treinta mil acciones, 1957–2016) y un conjunto de unas 94 características por acción, más interacciones sectoriales. Lo que encuentran sobre el peso relativo de las familias de variables tiene una lectura práctica clara. El *momentum* de precio, la reversión de corto plazo, la liquidez y la volatilidad concentran casi todo el poder predictivo, mientras que muchas variables fundamentales aportan poco al margen una vez que se controlan las técnicas.

En la práctica de la industria cuantitativa, estas ideas se concretan en conjuntos de variables estandarizados como *Alpha158* y *Alpha360*, que construyen, respectivamente, alrededor de 158 y 360 variables derivadas solo de precio y volumen (rendimientos retardados, medias móviles, desviaciones, indicadores de volatilidad y volumen a distintos horizontes). Estos conjuntos son atractivos porque se calculan sin datos fundamentales, pero al ser puramente técnicos tienen mucha colinealidad interna, de modo que sumar columnas no es lo mismo que sumar información independiente.

Frente a la acumulación de variables técnicas, la literatura de *factor investing* aporta familias fundamentales con base económica. El modelo de cinco factores de Fama y French [6] añade rentabilidad operativa (*RMW*) e inversión (*CMA*) a los factores clásicos de mercado, tamaño y valor; Novy-Marx [7] muestra que la rentabilidad bruta sobre activos predice retornos tan bien como el valor contable, y Ang et al. [8] documentan que la volatilidad idiosincrática (*IVOL*) se asocia de forma negativa a los retornos futuros (el llamado enigma de la baja volatilidad). Estas tres referencias justifican un núcleo reducido de variables fundamentales y de riesgo: rentabilidad/calidad, inversión y volatilidad idiosincrática.

La tensión entre acumular variables y consolidarlas es fuerte en el S&P 500. Con unas 477 acciones y del orden de 400 semanas, las observaciones cross-seccionales efectivas son pocas y están muy correlacionadas dentro de cada fecha; un conjunto de variables demasiado grande lleva al sobreajuste antes que a la mejora. La conclusión de diseño, en línea con Gu, Kelly y Xiu [2], es *consolidar, no acumular*: un núcleo técnico fuerte y unas pocas variables fundamentales y de riesgo con motivación económica. Como se verá en el Capítulo 6, esta decisión de ingeniería de variables pesa más en el retorno neto que la elección de la arquitectura.

2.3. Arquitecturas de aprendizaje profundo

En la literatura aplicada de los últimos años domina la idea de que arquitecturas cada vez más expresivas (*transformers*, modelos de espacio de estados (*state-space models*, SSM) tipo *Mamba*, y modelos fundacionales de series temporales (*time-series foundation models*, TSFM)) deberían mejorar siempre la predicción de retornos. La evidencia dice lo contrario, y sobre ella se apoya el segundo pilar de la tesis.

El resultado de partida (que aquí se llama *shallow beats deep*, lo superficial bate a lo profundo) viene de Gu, Kelly y Xiu [2]. Al comparar una batería de modelos sobre el panel estadounidense, encuentran que las redes neuronales con pocas capas ocultas (NN3–NN4, es decir, tres o cuatro capas) rinden mejor fuera de muestra, mientras que añadir profundidad (NN5) empeora. Los árboles potenciados (*gradient boosting*) y las redes superficiales son los que mejor van; la capacidad expresiva de más acaba en sobreajuste, no en señal.

La evidencia más reciente lleva esta conclusión a la era de los modelos fundacionales. El trabajo de Rahimikia y Poon [3] sobre predicción en regímenes cross-mercado va en la misma línea: los métodos de *boosting* de árboles (CatBoost, LightGBM) batan de forma consistente tanto a redes neuronales profundas como a modelos fundacionales de series temporales aplicados en modo *zero-shot* sobre miles de acciones estadounidenses; en ese régimen, los TSFM llegan a dar un R^2 fuera de muestra negativo. El mensaje coincide con el anterior: en datos financieros con poca señal frente al ruido, un modelo simple y regularizado va mejor que la flexibilidad de uno complejo.

2.4. Descomposición de señal y wavelets

Una de las ideas que justifican la complejidad de *Stockformer* es separar la serie de precios en componentes de distinta frecuencia antes de modelarla. La idea es que una serie financiera mezcla un componente de tendencia de baja frecuencia (ligado a momentum y a factores de medio plazo) con un componente de alta frecuencia (ruido de microestructura y reversión de corto plazo), y que conviene tratarlos por separado.

La herramienta habitual es la transformada *wavelet* discreta (*DWT*), cuyo marco multirresolución estableció Mallat [9]. A diferencia de la transformada de Fourier, que descompone la señal en frecuencias puras sin localización temporal, la descomposición multirresolución de Mallat representa la señal a varias escalas y conserva la localización en tiempo y en frecuencia. Eso la hace adecuada para series no estacionarias como los precios, donde el peso de cada escala cambia con el tiempo. En arquitecturas como *Stockformer*, esta descomposición sirve para alimentar ramas que modelan por separado las componentes de alta y baja frecuencia.

El enfoque es atractivo sobre el papel, pero tiene dos riesgos prácticos. El primero es metodológico. Una transformada *wavelet* aplicada de forma ingenua sobre toda la serie incurre en fuga de información (*look-ahead*), porque los coeficientes en un instante dependen de observaciones futuras dentro de la ventana de análisis; solo vale una implementación causal, calculada solo con información pasada en cada fecha, en un *backtest* honesto. El segundo afecta al coste-beneficio. La descomposición multiplica el número de canales y, con ello, la capacidad del modelo, lo que en un mercado de poca señal agrava el riesgo de sobreajuste que se comentó en la sección anterior.

2.5. Modelado de relaciones entre acciones con grafos

El supuesto de independencia entre acciones es falso. Las acciones comparten exposición a sectores, a factores y a cadenas de suministro, entre otras cosas. Una parte importante de la literatura reciente, incluida la que da origen a *Stockformer*, modela estas relaciones con grafos, donde los nodos son acciones y las aristas codifican algún tipo de relación.

Una vía para construir representaciones de nodos es *struc2vec* [10], que aprende *embeddings* a partir de la identidad estructural de los nodos, de modo que dos nodos con vecindarios parecidos reciben representaciones próximas aunque estén lejos en el grafo. Eso contrasta con métodos que solo capturan proximidad, y sirve para agrupar acciones por su papel estructural en la red de relaciones.

La distinción metodológica clave es entre grafos estáticos y dinámicos. Un grafo estático (por ejemplo, uno derivado de la pertenencia sectorial GICS) es estable y barato, pero no recoge que las correlaciones entre acciones cambian con el régimen de mercado, ya que suben en periodos de tensión y bajan en periodos de calma. Un grafo dinámico, reestimado en cada ventana, sí recoge esa variación, pero a costa de más complejidad, más parámetros y más riesgo de sobreajuste, así como de fuga de información si la estructura del grafo se estima con datos futuros. Esta tensión repite, en el dominio relacional, el mismo dilema de expresividad frente a sobreajuste de las secciones anteriores.

Para este trabajo, lo importante es que gran parte de la co-variación entre acciones se puede capturar de forma robusta con estructuras sencillas y con sentido económico (el sector y la exposición a factores comunes), sin tener que aprender un grafo dinámico. Esta idea reaparece en la neutralización por sector y factores de la construcción de cartera (Capítulo 6).

2.6. Funciones de pérdida para ranking

Para una cartera *long-short* market-neutral, el objetivo no es predecir el nivel exacto del retorno de cada acción, sino *ordenar* bien la sección cruzada, es decir, comprar las mejores y vender las peores. Eso convierte el problema en uno de aprendizaje de ordenación (*learning to rank*) más que de regresión, y la elección de la función de pérdida (*loss*) deja de ser un detalle técnico y pasa a ser una decisión de diseño con impacto económico.

El marco de referencia viene de la recuperación de información. Cao et al. [11] formalizan el paso del enfoque por pares (*pairwise*) al enfoque por listas (*listwise*) con *ListNet*, que define una distribución de probabilidad sobre permutaciones de la lista y minimiza la entropía cruzada respecto al orden objetivo. La ventaja es que *ListNet* optimiza la calidad del orden completo en lugar del error de predicción de cada elemento por separado, que es lo que hace el error cuadrático medio (*MSE*).

Llevar estas ideas a la predicción de retornos sugiere que entrenar con una pérdida de ordenación puede mejorar la rentabilidad de la cartera frente a entrenar con MSE, incluso cuando el error de regresión empeora. Evidencia reciente en esta línea [12] reporta mejoras del orden de 150–200 puntos básicos anuales al cambiar el MSE por pérdidas de *ranking* de tipo *listwise* o de margen en la predicción de retornos. Eso sí,

la pérdida hay que optimizarla para el objetivo de cartera y no para el IC, porque el mejor IC no coincide siempre con el mejor retorno neto una vez que se meten costes y restricciones de construcción.

En este trabajo, la función de pérdida es uno de los componentes que sí se exploran en la parte constructiva, y su elección se evalúa por su efecto sobre el *Sharpe* neto, no sobre el IC, en el Capítulo 6.

2.7. Metodología de entrenamiento

En predicción financiera, el riesgo de obtener resultados buenos de forma artificial por fuga de información o por sobreajuste al periodo de prueba es tan alto que aquí la metodología de entrenamiento se trata como un objeto de estudio en sí mismo.

La referencia principal es Prado [13], que ordena los modos de fuga típicos del aprendizaje automático financiero y propone remedios concretos. El principio rector es la evaluación *walk-forward*. El modelo se entrena con un bloque de datos pasado y se valida sobre el bloque siguiente, avanzando en el tiempo, de modo que nunca se usa información futura para predecir el pasado. A esto añade dos refinamientos esenciales cuando las etiquetas (*labels*) se construyen sobre ventanas solapadas: la *purga* (*purging*), que quita del conjunto de entrenamiento las observaciones cuyo horizonte de etiqueta solapa con el periodo de prueba; y el *embargo* (*embargo*), que descarta además un margen temporal tras el periodo de prueba para que la autocorrelación serial no filtre información.

El segundo riesgo es el sobreajuste por falta de observaciones cross-seccionales independientes. Como ya se ha dicho, en el S&P 500 las observaciones efectivas por fecha están muy correlacionadas, de modo que el número efectivo de grados de libertad es mucho menor que el que sugeriría el producto acciones $\times$ fechas. Gu, Kelly y Xiu [2] insisten en la necesidad de regularización fuerte y de validación estricta por esta razón. En este contexto, la búsqueda de hiperparámetros sobre el periodo de prueba, o la selección del modelo *a posteriori*, es un sobreajuste encubierto que infla las métricas que se reportan.

Para este trabajo, esto significa que toda la comparación entre *Stockformer* y los modelos simples se hace bajo un protocolo *walk-forward* con purga y embargo, y que las métricas se reportan siempre fuera de muestra. Este protocolo se detalla en el Capítulo 4 y es la condición que hace interpretables los resultados de los Capítulos 5 y 6.

2.8. Construcción y evaluación de cartera

La última sección conecta con la parte constructiva de la tesis. Una señal predictiva, por buena que sea, solo genera valor si se traduce en posiciones que sobreviven a los costes de transacción. Ese es el tercer pilar de la tesis: en el S&P 500 el retorno neto se gana en la construcción de la cartera, no en la capacidad predictiva del modelo.

El primer ingrediente es la estimación robusta de la matriz de covarianzas. La matriz muestral es inestable cuando el número de activos es parecido al número de observaciones, y eso degrada cualquier optimización de cartera. Ledoit y Wolf [14]

proponen el encogimiento (*shrinkage*) de la matriz muestral hacia un objetivo estructurado, lo que reduce el error de estimación y da carteras con menor volatilidad realizada y menor *drawdown*. El *shrinkage* de Ledoit–Wolf es hoy un estándar para dimensionar posiciones bajo objetivo de volatilidad.

El segundo ingrediente es la neutralización frente a factores conocidos. Hay características de las acciones que ya se sabe que pagan un retorno, como el tamaño, el valor, la rentabilidad y la inversión Fama y French [6], la rentabilidad bruta Novy-Marx [7] y la volatilidad idiosincrática Ang et al. [8]. Una señal predictiva puede estar apostando por estas características sin que el diseño lo busque; por ejemplo, una señal técnica que favorezca siempre a las empresas pequeñas ganará dinero cuando el factor tamaño lo gane, sin haber predicho nada. Neutralizar consiste en quitar de la señal esa parte que explican los factores y el sector, de modo que el retorno que queda mida lo que la señal aporta por sí misma y no una apuesta factorial encubierta.

El tercer ingrediente es tener en cuenta los costes y el régimen de mercado. Cada operación tiene un coste, así que una cartera que rota mucho puede perder en costes todo lo que su señal gana en bruto. La solución es que el propio optimizador penalice la rotación (por ejemplo, con una penalización L_1 sobre los cambios de posición), de forma que solo opere cuando la ganancia esperada compensa el coste [15]. A los costes se suma un riesgo de cola propio del momentum: Daniel y Moskowitz [16] documentan que estas estrategias sufren desplomes fuertes (*momentum crashes*) en las salidas de mercados bajistas, cuando la volatilidad es alta y el mercado rebota. La defensa práctica es un solapamiento por régimen (*regime overlay*), esto es, bajar la exposición de la cartera cuando la volatilidad del mercado es alta [17]. Por último, la medida más eficaz para preservar el retorno neto es también la más simple: rebalancear cada semana en lugar de cada día, lo que reduce la rotación, y con ella los costes, en un orden de magnitud parecido al cambio de frecuencia.

Para este trabajo, esto significa que la construcción de cartera (encogimiento de covarianzas, neutralización factorial, optimización consciente de costes, rebalanceo semanal y solapamiento por régimen) es el núcleo de la propuesta que *sí* genera retorno neto positivo en el S&P 500, y se desarrolla en detalle en el Capítulo 6.

Capítulo 3

Arquitectura original de Stockformer

El modelo Stockformer, propuesto por Ma et al. [1] para el mercado de acciones *A-shares* chino, junta en una sola red neuronal varios componentes que en la literatura suelen aparecer por separado. Son una representación densa de precio y volumen, una descomposición de la señal en frecuencias, un codificador espacio-temporal basado en atención, un grafo estático de relaciones entre acciones y un cabezal de predicción multitarea. Este capítulo describe esa arquitectura original tal y como está implementada, sin entrar todavía en la cuestión de su transferibilidad al mercado estadounidense, que se aborda en el capítulo 5. La idea es distinguir *qué* se adapta y *qué* se conserva en la Parte I, para que la discusión de resultados que viene después se pueda atribuir a decisiones concretas de diseño.

3.1. Conjunto de variables Alpha360

La entrada del modelo no son los precios brutos. Es un conjunto de variables derivadas conocido como *Alpha360*. La idea, heredada de la biblioteca Qlib y usada de forma generalizada en la literatura de predicción bursátil [2], es describir cada acción mediante un *perfil temporal*. En lugar de modelar la serie de precios completa, se resume la historia reciente de cada activo en un vector de tamaño fijo que captura cómo se ha movido el precio y el volumen a lo largo de las últimas semanas de cotización.

Concretamente, se parte de seis campos de mercado: apertura (*open*), máximo (*high*), mínimo (*low*), cierre (*close*), precio medio ponderado por volumen (*vwap*) y volumen (*volume*). Para cada uno se construyen 60 variables correspondientes a 60 desfases temporales (*lags*) $d = 1, 2, \dots, 60$. El producto $6 \times 60 = 360$ da nombre al conjunto. Cada variable se define como un cociente respecto a un valor de referencia reciente. Para los cinco campos de precio, el denominador es el cierre desfasado d jornadas:

$$\text{CLOSE}_d = \frac{\text{Close}_t}{\text{Close}_{t-d}}, \quad \text{OPEN}_d = \frac{\text{Open}_t}{\text{Close}_{t-d}}, \quad \text{VWAP}_d = \frac{(\text{High}_t + \text{Low}_t + \text{Close}_t)/3}{\text{Close}_{t-d}},$$

con expresiones análogas para máximo y mínimo. El volumen, por su distinta escala, se normaliza contra su propio pasado, $\text{VOL}_d = \text{Volume}_t / \text{Volume}_{t-d}$. El *vwap* se aproxima con el precio típico $(\text{High} + \text{Low} + \text{Close})/3$ cuando no hay un *vwap* transaccional verdadero.

Esta parametrización tiene dos propiedades. La primera es la *normalización por el valor más reciente*. Al dividir por un precio de referencia próximo, cada variable expresa una variación relativa y no un nivel absoluto, así que acciones de muy distinto precio nominal son comparables y el perfil es casi invariante a la escala del activo. La segunda es que, al recorrer los 60 desfases, el vector resultante describe de forma implícita la *trayectoria reciente* de cada acción (su tendencia, aceleración y patrón de volumen) sin necesidad de un modelo recurrente explícito.

En la implementación que sirve de base a este trabajo, cada una de las 360 variables se estandariza además de forma *transversal* (*cross-sectional z-score*). Para cada jornada se resta la media y se divide por la desviación típica calculadas sobre todas las acciones de ese día. Esta normalización por sección se hace por filas (a través de los activos), nunca por columnas (a lo largo del tiempo), porque una estandarización temporal metería información futura y sería una fuga de datos. Los valores no definidos (divisiones por cero o cocientes infinitos) se reemplazan por cero, que tras la estandarización coincide con la media transversal. Por construcción, el desfase máximo $d = 60$ invalida las primeras 60 jornadas de la muestra (donde el pasado requerido no existe), que se descartan antes de alimentar el modelo.

3.2. Descomposición wavelet (DWT Sym2)

El Stockformer no procesa la señal de entrada de una pieza. Antes la descompone en una componente de baja frecuencia y otra de alta frecuencia con la *transformada wavelet discreta* (*Discrete Wavelet Transform*, DWT). La motivación es la clásica separación entre señal y ruido. La componente de baja frecuencia recoge la *tendencia* suave y persistente del precio, y la de alta frecuencia concentra las fluctuaciones rápidas y el ruido a corto plazo. Tratar ambas por canales distintos deja que el modelo aprenda dinámicas distintas para cada escala temporal, en lugar de promediarlas en una sola representación.

La transformada empleada utiliza la wavelet *Symlet-2* (*sym2*) con un único nivel de descomposición ($J = 1$). Sobre cada serie temporal de la ventana de entrada, la transformada directa produce un conjunto de coeficientes de aproximación (baja frecuencia) y otro de coeficientes de detalle (alta frecuencia).

En la implementación, la descomposición no se queda en el dominio de los coeficientes. Cada banda se *reconstruye* de vuelta al dominio temporal original con la transformada inversa, anulando la otra banda. Es decir, la componente de baja frecuencia X_L se obtiene aplicando la inversa con los coeficientes de detalle puestos a cero, y la de alta frecuencia X_H haciendo lo mismo con los coeficientes de alta. El resultado son dos series del mismo tamaño que la original (una suavizada y otra con solo el residuo de alta frecuencia) que suman aproximadamente la señal de partida. Estas dos series, X_L y X_H , son las que alimentan los dos canales del codificador.

3.3. Encoder espacio-temporal de doble canal

El núcleo del modelo es un codificador (*encoder*) que procesa en paralelo las dos bandas de frecuencia y que, en cada bloque, combina dos ejes de información. Uno es el *temporal* (la dinámica de cada acción a lo largo de la ventana de *lookback*) y

el otro el *espacial* (las relaciones de cada acción con las demás del universo). En la configuración base, la ventana de entrada cubre $T_1 = 20$ jornadas y se apilan $L = 2$ bloques codificadores de dimensión interna 128.

Antes de entrar al codificador, las dos bandas se proyectan a la dimensión interna del modelo mediante sendas capas de inicio (*start embedding*) y se les suma un *embedding* temporal que codifica el día de la semana y la posición dentro de la ventana. Durante el entrenamiento se inyecta además un pequeño ruido gaussiano sobre ambas bandas, que actúa como regularización implícita.

Cada bloque del codificador trata las dos bandas de manera asimétrica, según su distinta naturaleza:

- La banda de baja frecuencia X_L se procesa con *atención temporal* (*self-attention* sobre el eje del tiempo). La atención usa una *máscara causal* triangular inferior, de modo que la representación de cada jornada solo puede atender a jornadas presentes y pasadas, nunca futuras. Es una salvaguarda explícita contra la fuga de información temporal.
- La banda de alta frecuencia X_H se procesa con una red *convolucional temporal* (*Temporal Convolutional Network*, TCN) de convoluciones dilatadas y causales, más adecuada que la atención global para capturar patrones locales de corta escala.

Tras el tratamiento temporal, ambas bandas pasan por un componente *espacial* de *atención dispersa* (*sparse spatial attention*) que opera entre acciones. Para cada activo calcula puntuaciones de atención frente al resto del universo y agrega información de los demás. La variante implementada añade una operación de *copia* que, para cada acción, escoge la acción que más le atiende y propaga su representación, en lugar de una mezcla densa de todos los pares; esto reduce el coste de memoria respecto a una atención completa entre acciones. Cada uno de los dos canales tiene su propio módulo espacial, y la salida se conecta de forma residual con la entrada del bloque.

A la salida de los L bloques, una capa de *fusión adaptativa* (*adaptive fusion*) combina ambos canales. Esta fusión es otra vez un mecanismo de atención, pero cruzado. Las consultas (*queries*) vienen de la banda de baja frecuencia y las claves y valores de la de alta frecuencia, de modo que el modelo aprende a modular la tendencia con la información de detalle. La fusión opera ya sobre el horizonte de predicción $T_2 = 2$, al que las dos bandas se han reducido con una proyección convolucional desde las $T_1 = 20$ jornadas de entrada. El resultado son dos representaciones por acción (la fusionada y la propia de la banda de baja frecuencia) que se pasan a los cabezales de salida.

3.4. Embeddings de grafo (struc2vec)

El componente espacial descrito en la sección anterior necesita saber *a priori* qué acciones están relacionadas. El Stockformer no lo aprende desde cero. Lo inyecta a través de un *grafo estático* de relaciones entre acciones, precomputado y codificado en *embeddings* de nodo con el algoritmo *struc2vec* [10].

El grafo se construye a partir de la matriz de correlaciones de los retornos. Se calcula la correlación de Pearson entre cada par de acciones sobre el periodo de entrenamiento

y se guardan como aristas los pares cuya correlación supera en valor absoluto un umbral (en la implementación, $|\rho| > 0,3$). El resultado es una lista de aristas ponderadas que define la topología del universo.

Sobre esa topología se aplica struc2vec, un método de aprendizaje de representaciones de nodos que mide la *similitud estructural*. Es decir, dos acciones reciben *embeddings* próximos si ocupan posiciones topológicamente parecidas en el grafo (por ejemplo, ambas como nodos centrales muy conectados o ambas periféricas), aunque no estén vinculadas directamente entre sí. El algoritmo genera una jerarquía de similitudes, hace caminatas aleatorias (*random walks*) sobre el grafo de contexto resultante y entrena un modelo tipo *skip-gram* para producir un vector por acción. En la configuración base, cada acción se representa con un *embedding* de dimensión 128.

3.5. Cabezas multitarea

El Stockformer aprende de forma *multitarea* (*multi-task*), no como un modelo de regresión puro. Tiene dos cabezales de salida que comparten el mismo cuerpo codificador pero optimizan objetivos distintos:

- Un cabezal de regresión, que predice el retorno futuro de cada acción (la magnitud de la señal).
- Un cabezal de clasificación, que predice la *dirección* o tendencia del activo (señal discreta de subida o bajada), planteado como un problema de clasificación sobre un número fijo de clases.

Cada cabezal es una pequeña red *feed-forward* y, en la implementación, se aplica a las dos representaciones que entrega el codificador (la fusionada y la de la banda de baja frecuencia), así que la señal de regresión y la de clasificación se obtienen por partida doble. La función de pérdida combina los dos objetivos: una *entropía cruzada* (*cross-entropy*) para la cabeza de clasificación y un *error absoluto medio enmascarado* (*masked MAE*) para la de regresión, donde el enmascarado descarta las posiciones sin etiqueta válida. La pérdida total es una suma ponderada de ambos términos, lo que obliga al cuerpo compartido a aprender una representación útil a la vez para anticipar el signo y la magnitud del movimiento.

El supuesto de fondo es que la tarea de clasificación direccional actúa como una señal auxiliar que regulariza la regresión. Ordenar bien las acciones por dirección es un objetivo más robusto al ruido que estimar el retorno exacto, y su gradiente ayuda a estabilizar el aprendizaje.

En la adaptación al S&P 500 estudiada en la Parte I, se cambia solo el *término de regresión* de este objetivo multitarea. El MAE enmascarado se sustituye por una pérdida de *ranking* transversal (una combinación de pérdida listwise tipo *ListNet* [11], un término que optimiza directamente el coeficiente de información (*Information Coefficient*, IC) y un término MAE), porque está mejor alineada con el objetivo último de seleccionar acciones. El cabezal de *clasificación de signo* se conserva (entropía cruzada, con peso 0,5 en la suma total), de modo que la pérdida efectiva es *híbrida* (*ranking* en la regresión más clasificación direccional auxiliar) y mantiene la estructura multitarea en vez de reemplazarla por completo; la motivación de ese cambio se detalla en el capítulo 4.

3.6. Configuración de entrenamiento

La adaptación al S&P 500 se entrena con una sola configuración, fijada de antemano y resumida en la Tabla 3.1. El modelo recibe ventanas de $T_1 = 20$ jornadas de entrada y emite un horizonte interno de $T_2 = 2$ pasos; como la etiqueta es el retorno a un día, la predicción operativa es la del *último* paso del horizonte, y sobre ese paso final se calculan el IC transversal y la cartera. La optimización usa Adam con tasa de aprendizaje 10^{-3} , *weight decay* 10^{-5} y recorte de la norma del gradiente a 0,3; un planificador *ReduceLROnPlateau* baja la tasa por un factor 10 cuando el IC de validación deja de mejorar. El criterio de selección del *checkpoint* es el mejor IC de validación, y el entrenamiento se para de forma anticipada tras 15 épocas sin mejora, de un máximo de 50. La pérdida combina el término de *ranking* transversal en la regresión (ListNet con peso 0,5, IC con 0,3 y MAE con 0,2) y la clasificación de signo con peso 0,5. El entrenamiento es de una sola semilla, limitación que se discute en el capítulo de discusión. El modelo resultante tiene 1,041,755 parámetros, del orden de 10^6 .

Tabla 3.1: Configuración de entrenamiento del Stockformer en el S&P 500.

Hiperparámetro	Valor
Ventana de entrada T_1 / horizonte T_2	20 / 2 (se evalúa el último paso)
Optimizador	Adam, lr = 10^{-3} , <i>weight decay</i> = 10^{-5}
Recorte de gradiente	norma $\leq 0,3$
Planificador de lr	ReduceLROnPlateau (factor 0,1, paciencia 20, sobre IC val.)
Épocas / parada temprana	máximo 50; paro tras 15 épocas sin mejora de IC
Selección de <i>checkpoint</i>	mejor IC de validación
Tamaño de lote	12
Semilla	1 (única ejecución)
Regularización	<i>dropout</i> 0,2, ruido gaussiano $\sigma = 0,01$
Descomposición / grafo	DWT Sym2, nivel 1 / grafo estático <i>struc2vec</i>
Arquitectura	2 capas, 1 cabezal, dimensión 128
Pérdida	<i>ranking</i> (ListNet 0,5 + IC 0,3 + MAE 0,2) + clasif. 0,5
Parámetros entrenables	1,041,755

3.7. Resultados originales y supuestos de mercado

En su evaluación original sobre los índices chinos CSI 300 y CSI 500, Ma et al. [1] reportan un poder predictivo positivo, con un coeficiente de información (IC) transversal superior al de los modelos de referencia y, a partir de él, carteras *long-short* con ratios de Sharpe altos. Esa magnitud no es rara en ese régimen. En el mismo mercado chino, el transformer MASTER alcanza un IC en torno a 0,064 sobre CSI 300 [4], una magnitud que en mercados desarrollados casi nunca se sostiene fuera de muestra: unas 2,7 veces el mejor IC obtenido aquí sobre el S&P 500 (el Lasso de cinco coeficientes, +0,0238). La cuestión, entonces, no es si el modelo funciona en su entorno original (lo hace), sino por qué funciona allí y si esas condiciones se dan también en el S&P 500.

La respuesta apunta a la estructura del mercado chino, cuyas particularidades favorecen de forma sistemática las señales de momento y reversión que capturan las

variables Alpha360:

- Dominio del inversor minorista. El mercado chino está muy dominado por inversores *retail*, cuyo comportamiento gregario y sesgado genera patrones de precio más persistentes y predecibles que los de un mercado institucionalizado.
- Menor eficiencia informativa. La información entra en los precios más despacio, de modo que las señales técnicas conservan poder predictivo durante más tiempo antes de ser arbitradas.
- Límites diarios de precio. Las *A-shares* están sujetas a bandas de fluctuación diaria (típicamente $\pm 10\%$) que detienen la cotización al tocar el límite. Estos toques meten autocorrelación mecánica en los retornos, ya que una acción que toca el límite superior tiende a seguir al alza la jornada siguiente. Un modelo puede aprender esa regularidad e inflar de forma artificial su IC, pero esa señal es en buena medida *no ejecutable*, porque cuando el modelo querría comprar, la acción está bloqueada en el límite y no hay contrapartida disponible.

Estos tres rasgos hacen del mercado chino un entorno benigno para un modelo como el Stockformer. El S&P 500, en cambio, es uno de los mercados más líquidos y eficientes del mundo, sin límites diarios de precio y con costes de transacción y arbitraje que erosionan deprisa cualquier señal técnica. Ninguno de los supuestos anteriores se sostiene. Esta asimetría es la que motiva la pregunta central del capítulo 5. ¿Transfiere el Stockformer su desempeño cuando se le quita el régimen de mercado que lo hacía funcionar? Y, de no hacerlo, ¿cuánto de su arquitectura hace falta de verdad? El resto de la memoria se ocupa de responder ambas preguntas a partir de la evidencia empírica.

Capítulo 4

Metodología

Este capítulo describe la metodología que comparten las dos partes empíricas de la memoria. El trabajo tiene dos pasos. Primero se intenta transferir el modelo Stockformer (capítulo 3) al mercado estadounidense (Parte I, capítulo 5) y después se construye una estrategia que sí genera retorno neto (Parte II, capítulo 6). Los dos pasos usan una misma infraestructura de datos, variables, evaluación y control de fugas de información. Describirla una sola vez, antes de presentar los resultados, hace que la comparación entre modelos sea homogénea, porque todos ven los mismos datos, la misma alineación temporal y el mismo instrumento de medida, y lo único que cambia de un modelo a otro es el modelo. Esa exigencia de entradas idénticas en los que solo cambia el predictor es el eje metodológico del trabajo, y es lo que hace interpretable cualquier diferencia de rendimiento observada.

4.1. El universo S&P 500 y el panel de datos

El universo de estudio es el conjunto de componentes del índice S&P 500, de los que se conservan las ~ 477 acciones con cobertura completa de precios en la ventana considerada. Los datos de mercado (apertura, máximo, mínimo, cierre y volumen, es decir, *OHLCV*) se descargan de Yahoo Finance y se guardan como ficheros Parquet por *ticker*, uno por acción, con un calendario de negociación común. El panel cubre desde el 2 de enero de 2018 hasta el 12 de marzo de 2026, 2.059 días de negociación, y conserva las ~ 477 acciones con cobertura completa en ese periodo. La elección del S&P 500 tiene un motivo. El Stockformer se calibró sobre acciones chinas *A-shares* (índices CSI 300/500), un mercado cuya microestructura (límites diarios de precio, presencia minorista alta, restricciones a la venta en corto) es muy distinta de la del mercado estadounidense.

A partir de los ficheros OHLCV se construye un panel transversal de la forma $[T, N, F]$, donde para cada uno de los T días de negociación y cada una de las N acciones del universo se guarda un vector de F variables explicativas. La etiqueta a predecir es el retorno futuro a un día, $y_{t,i} = \text{Close}_{t+1,i} / \text{Close}_{t,i} - 1$, guardado como una matriz $[T, N]$ alineada con el panel de variables. El Stockformer opera internamente con un horizonte de $T_2 = 2$ pasos, pero la predicción operativa que entra en el IC y en la cartera es la del último paso, alineada con esta etiqueta a un día. El panel se carga en una estructura inmutable con las variables, las etiquetas, el calendario, la lista de *tickers* y los índices de corte del *split* temporal.

Alineación variable–etiqueta. El invariante anti-leakage central del panel es el desfase (*offset*) de 60 filas entre la rejilla bruta de precios y el panel emparejado. Las variables Alpha360 necesitan un *buffer* de 60 retardos (*lags*) para estar definidas, así que las primeras 60 filas del panel bruto se descartan, y la primera fila de variables corresponde al día 60 del calendario original. La etiqueta se recorta con el mismo desfase, de manera que esa fila se empareja con su *propia* etiqueta del mismo día, el retorno a un día $y_{60} = \text{Close}_{61}/\text{Close}_{60} - 1$. Las variables observadas el día t se asocian al retorno a un día $y_t = \text{Close}_{t+1}/\text{Close}_t - 1$, y el 60 es solo el número de filas que se descartan, no un horizonte de predicción. Este mismo desfase se aplica igual a todas las ramas del trabajo (la del Stockformer y la de los modelos tabulares) y es lo que verifica la auditoría de la sección 4.6.

Split fijo estándar. Para la comparación de modelos de la Parte I se emplea una división temporal fijo en proporciones 0,75/0,125/0,125 (entrenamiento, validación y test) sobre el conjunto. El panel alineado tiene 1.999 días y arranca el 29 de marzo de 2018, tras descartar el buffer de 60 filas; sobre esa longitud, las proporciones sitúan los cortes en entrenamiento del 29 de marzo de 2018 al 13 de marzo de 2024 (1.499 días), validación del 14 de marzo de 2024 al 13 de marzo de 2025 (250 días) y test del 14 de marzo de 2025 al 12 de marzo de 2026 (250 días). Todas las estadísticas de normalización se estiman *solo* sobre el tramo de entrenamiento y se aplican después a validación y test, para que no se filtre información futura. Cada modelo trabaja sobre la versión aplanada del panel, en la que cada fila es un par (fecha, acción) y se descartan las filas con cualquier valor ausente. El conjunto de variables base (*F-base*) son las variables Alpha360 más los indicadores técnicos de Alpha158 (sección 4.2) y excluye las variables macroeconómicas, que son constantes en sección transversal y, por tanto, no aportan información de *ranking*. El estándar acordado es que esos $F \approx 375$ regresores idénticos alimenten a todos los modelos, lineales y de árboles por igual.

Evaluación temporal walk-forward. Para la estrategia semanal de la Parte II un único *split* fijo no basta, porque podría atribuirse a la estrategia un rendimiento que dependa de una ventana favorable. Por ello la evaluación temporal de la Parte II sigue un protocolo *walk-forward* con reentrenamiento periódico. Se entrena el modelo sobre una ventana inicial (~ 200 semanas, unos cuatro años, hasta finales de 2021), se predice *fuera de muestra* hasta el siguiente reentrenamiento (cada ~ 26 semanas, semestralmente) y se concatenan todos los tramos fuera de muestra en una única curva de *equity* sobre la que se reportan el Sharpe neto global y por segmentos anuales. Sobre el panel completo (de unas 427 semanas, en torno a ocho años) se emplean dos calibraciones de este mismo protocolo. La principal arranca con una ventana inicial de ~ 200 semanas y concatena unas 215 semanas fuera de muestra, de finales de enero de 2022 al 6 de marzo de 2026 (Tabla 6.2). La búsqueda de señal de la Parte II parte antes, con una ventana inicial de ~ 104 semanas, para disponer de una ventana fuera de muestra más larga, de 311 semanas (del 27 de marzo de 2020 al 6 de marzo de 2026), que incluye el *momentum-crash* de 2021; de ellas, las 104 últimas se reservan como *holdout*. En ambos casos la ventana inicial más las semanas fuera de muestra suman la misma longitud del panel.

El protocolo es *purgado*, porque entre el final del tramo de entrenamiento y el inicio del de predicción media siempre el horizonte de la etiqueta, así que ninguna observación

de entrenamiento solapa con el periodo evaluado. Y es *embargado* porque el modelo nunca ve información posterior al instante de la decisión. Tratar así el solapamiento temporal de etiquetas es práctica estándar en *machine learning* financiero [13].

Por qué la complejidad admisible está acotada. Hay un dato cuantitativo que condiciona toda la estrategia de modelado. Aunque el panel tiene ~ 477 acciones y centenares de fechas, decenas de miles de pares (fecha, acción), las observaciones transversales *efectivas* son muchas menos. Las acciones de un mismo día comparten un factor de mercado dominante y comovimientos sectoriales, y están muy correlacionadas dentro de cada fecha. El número de fechas independientes es, en la práctica, del orden de unos pocos cientos. Aunque el panel reúne ~ 477 acciones $\times \sim 400$ semanas, la alta correlación dentro de cada fecha hace que esos pares (fecha, acción) no sean independientes, y los grados de libertad efectivos quedan muy por debajo de las decenas de miles que sugiere la entrada al modelo. Eso tiene un efecto directo. Un modelo con muchos parámetros sobreajusta el ruido idiosincrásico antes de capturar señal real. Este límite motiva la hipótesis *simpler-is-better* de la sección 4.4 y la consigna de *consolidar variables, no acumularlas* de la sección 4.2, y es coherente con la literatura de *asset pricing* con *machine learning*, donde los modelos superficiales tienden a batir a los profundos [2].

4.2. Ingeniería de variables

El conjunto de variables explicativas se organiza en tres familias, todas calculadas a partir de los datos OHLCV y de unas pocas series macroeconómicas, y todas sometidas a un mismo protocolo de limpieza sin fuga de información.

Alpha360. La familia principal reproduce la formulación Alpha360, también empleada por el Stockformer original. Se generan $6 \times 60 = 360$ variables por acción y día, esto es, para cada uno de seis campos de precio/volumen y cada retardo $d \in \{1, \dots, 60\}$, un cociente que normaliza el campo actual por el cierre (o el volumen) de d días atrás. Concretamente, con $VWAP = (High + Low + Close)/3$,

- $CLOSE_dd = Close_t / Close_{t-d}$,
- $OPEN_dd = Open_t / Close_{t-d}$, $HIGH_dd = High_t / Close_{t-d}$, $LOW_dd = Low_t / Close_{t-d}$,
- $VWAP_dd = VWAP_t / Close_{t-d}$,
- $VOL_dd = Volume_t / Volume_{t-d}$.

Estos cocientes codifican de forma compacta momentum, reversión y dinámica de volumen a distintos horizontes. El cálculo usa división segura ante denominadores nulos, sustituye infinitos y ausentes, y descarta el *buffer* de 60 filas iniciales para que todos los cocientes estén definidos.

Alpha158 (indicadores técnicos). Como complemento, un segundo conjunto añade indicadores de análisis técnico estándar. Son el RSI a 6/12/24 días, la anchura y el %B de bandas de Bollinger, la señal e histograma del MACD, *Average True Range* normalizado por precio, *Rate of Change* a 5/10/20 días y volatilidad realizada a 5/10/20 días anualizada. Cada indicador se calcula por acción y se normaliza con el mismo procedimiento transversal, y se alinea al rango de fechas de Alpha360.

Variables macroeconómicas. Una tercera familia incorpora el estado del régimen de mercado que el precio individual no captura: nivel del VIX, su cambio a 5 días y su *z-score* a 20 días, así como el *term spread* entre los tipos a 10 años y a corto plazo (TNX–IRX) y su cambio a 5 días. Estas series se normalizan con un *z-score* temporal de ventana móvil de 60 días, sin mirar al futuro, y se replican (*broadcast*) a todas las acciones de cada fecha. Por construcción son constantes en sección transversal y, por ello, se excluyen del conjunto base usado para el *ranking* de acciones.

Limpieza transversal sin leakage. Aquí importan el orden y la dirección del procesamiento. Toda normalización se aplica *por fecha* y *en sección transversal* (a lo largo de las acciones, eje de *tickers*), nunca a lo largo del tiempo, porque normalizar en el eje temporal usaría estadísticas que mezclan pasado y futuro y metería fuga de información de anticipación (*look-ahead*). El procedimiento de higiene, descrito en la propuesta de *pipeline* de retornos, encadena para cada fecha:

1. **Winsorización** al 1/99 para acotar el efecto de valores extremos;
2. **Gaussian-rank** (transformación del rango a cuantiles gaussianos), preferible al *z-score* simple para variables con colas pesadas como fundamentales o sentimiento;
3. **Neutralización** del residuo frente a $\log(\text{mcap})$ y al sector GICS, de modo que la variable no codifique implícitamente una apuesta de tamaño o de sector.

En la implementación de Alpha360/Alpha158 la normalización transversal se aplica como *z-score* por fila, con relleno a cero (el valor neutro, igual a la media transversal tras estandarizar) para infinitos y ausentes. La consigna general, que viene del límite de ~ 400 observaciones efectivas de la sección anterior, es *consolidar* en unas pocas decenas de variables informativas en lugar de acumular centenares, para no sobreajustar.

4.3. Harness de evaluación

Todos los modelos se miden con un único instrumento de evaluación, compartido por los modelos lineales, los de árboles y el Stockformer. Que la medida sea idéntica para todos hace la comparación consistente y homogénea. El *harness* recibe dos paneles alineados (la predicción y la etiqueta realizada, ambos en el marco [fechas $\times$ tickers]) y devuelve el conjunto completo de métricas que usa la memoria. La metodología sigue la práctica habitual en *asset pricing* con *machine learning* [2].

Métricas de poder predictivo. La métrica primaria es el rank IC (*Information Coefficient*): la correlación de Spearman, en sección transversal y para cada fecha, entre el *score* predicho y el retorno realizado. Días con menos de dos pares válidos o con predicciones/etiquetas constantes, que no aportan información de *ranking*, se marcan como indefinidos. A partir de la serie diaria de IC se calculan su media, su desviación, el **ICIR** (media sobre desviación, una medida de estabilidad de la señal), el porcentaje de días con IC positivo y el número de días válidos. Se reportan también el IC de Pearson y, en otras secciones, métricas puntuales auxiliares (precisión direccional, MAE y RMSE). La métrica que gobierna las decisiones es el rank IC, porque se corresponde de forma directa con el objetivo de *ranking* de la cartera.

Inferencia con bootstrap y contrastes. Sobre la serie diaria de IC se construye un **intervalo de confianza bootstrap** para la media del IC, remuestreando días de negociación con reemplazo (2000 réplicas en las ejecuciones de la *ladder*). Para contrastar si una señal tiene poder predictivo en la realidad se aplica un **contraste t** de una muestra sobre la serie diaria de IC (H_0 : media del IC = 0). Para comparar dos modelos entre sí se emplea un **contraste t pareado** sobre la diferencia diaria de sus series de IC, alineadas en las fechas comunes; este contraste pareado es el que sustenta las afirmaciones de significancia entre modelos de la Parte I.

Backtest long-short por deciles. El harness incluye un *backtest* factorial *long-short dollar-neutral*. Cada día se ordenan las acciones por *score*, se compra el decil superior y se vende en corto el decil inferior; el retorno realizado usa la propia etiqueta, de modo que el *backtest* es plenamente reproducible sin necesidad de descargar precios. El retorno neto resta el coste de *turnover* (10 puntos básicos por lado en la *ladder*). Este nivel es conservador, porque la *ladder* opera un *long-short* por deciles equiponderado sobre el panel completo, con mayor rotación y sin construcción consciente del coste. La Parte II, restringida a un universo *large-cap* más líquido y con una optimización que internaliza la rotación, asume un coste algo menor, de 8 puntos básicos por lado. Ninguna conclusión depende de esta diferencia.

De la serie de retornos se derivan las métricas de rendimiento: retorno anualizado, ratio de Sharpe (con $r_f = 0$ y desviación muestral), *max drawdown*, retorno total y α/β frente a un proxy de mercado. La advertencia metodológica, que se desarrolla en la sección 4.5, es que el modelo de mejor IC no es necesariamente el de mejor retorno neto.

4.4. La complexity ladder

El diseño experimental central de la Parte I es una escalera de complejidad (*complexity ladder*): una secuencia de modelos ordenados por número de parámetros y evaluados todos sobre el mismo panel, las mismas variables, el mismo *split* y el mismo *harness*. Solo cambia el estimador. Los niveles son:

- **LO** (*sanity*): señales sin entrenamiento que fijan el suelo de referencia. *Zero* (sin posición), *momentum* transversal (retorno acumulado a 20 días) y *reversal* de corto plazo (5 días). Permiten detectar errores de canalización y situar el cero informativo.

- **L1** (lineal): regresores lineales regularizados (*Lasso*, *Ridge* y *ElasticNet*) sobre las variables estandarizadas con estadísticas *solo* de entrenamiento. Son modelos de muy pocos grados de libertad efectivos (el Lasso, por su penalización L_1 , retiene apenas un puñado de coeficientes no nulos).
- **L2** (árboles): *gradient boosting* con *LightGBM* y *XGBoost*, con pérdida robusta (Huber/pseudo-Huber), submuestreo de filas y columnas y regularización Ridge.
- **Cúspide** (Stockformer): el modelo *wavelet-transformer-grafo* multitarea de $\sim 10^6$ parámetros (capítulo 3), evaluado con el mismo *harness* a partir de su salida de inferencia guardada y con las mismas fechas reales de test.

El reparto de cómputo sigue esta misma división. Todo el entrenamiento y la evaluación de Stockformer, el único modelo que necesita GPU, se ejecutaron en la estación NVIDIA DGX de la Universidad. El resto del trabajo (los peldaños de CPU de la escalera, la estrategia semanal y los análisis de robustez de la Parte II) corre entero en CPU, porque su carga computacional es mucho menor.

La escalera responde a una hipótesis, la hipótesis ***simpler-is-better***: *si la complejidad del modelo aportara poder predictivo en un mercado eficiente como el S&P 500, el IC debería crecer monótonamente al subir por la escalera*. Lo contrario, que el IC *no* aumente con la complejidad (o incluso baje), indicaría que las arquitecturas complejas no transfieren y que los modelos simples llevan ventaja. Esta es la predicción de la literatura de *shallow-beats-deep* en *asset pricing* [2], donde los mejores estimadores son árboles y redes superficiales, mientras que las redes profundas tienden a empeorar. La *ladder* es un diseño *comparativo*. Su valor no está en el rendimiento absoluto de ningún modelo. Está en la pendiente IC-vs-complejidad que dibuja el conjunto.

4.5. Función de pérdida de ranking

Una decisión metodológica transversal es lo que optimizan los modelos. El objetivo último de la estrategia es ordenar bien las acciones de forma transversal, no predecir el retorno puntual de cada una. La cartera *long-short* compra las mejores y vende las peores, así que lo único que importa es el orden relativo, no el valor exacto del retorno. Por eso optimizar el error cuadrático medio (MSE), que es la pérdida por defecto de una regresión, optimiza un objetivo que no coincide con el de la cartera. El MSE penaliza por igual errores en acciones del centro del *ranking* (irrelevantes para la cartera) y en los extremos (decisivos), y se deja arrastrar por la magnitud de los retornos en lugar de por su orden.

Por ello el trabajo usa una pérdida de *ranking* combinada, en lugar del MSE. La pérdida integra tres componentes complementarios:

- un término **ListNet**, que trata el problema como aprendizaje de un orden (*learning-to-rank*) comparando la distribución de probabilidad sobre el *ranking* predicho con la del *ranking* verdadero;
- un término de **IC**, que optimiza directamente la correlación transversal que se va a medir y a explotar en la cartera;

- un término de **MAE**, que mantiene la predicción anclada a una escala razonable de retornos y estabiliza el entrenamiento.

Todos los modelos persiguen el mismo objetivo, ordenar bien la sección transversal, y se miden con el mismo instrumento, el rank IC. Lo que cambia entre ellos es cómo lo aprenden. El Stockformer entrena directamente para el orden, con una pérdida de *ranking* (la combinación ListNet+IC+MAE) más un cabezal auxiliar que clasifica el signo del retorno; se hace así porque optimizar el orden, y no el error punto a punto, suele dar mejores carteras que el MSE. Los modelos lineales (Lasso, Ridge, *Elastic-Net*) no admiten esa pérdida y minimizan el error cuadrático con penalización L_1/L_2 . LightGBM y XGBoost sí podrían usar objetivos de *ranking* (LambdaRank, NDCG), pero aquí se quedan en su objetivo estándar de regresión para que la comparación aísle la arquitectura y no la función de pérdida. Así, la pérdida de *ranking* la recibe solo el Stockformer, lo que si acaso le da ventaja; y aun así no transfiere.

Advertencia metodológica sobre IC y retorno. Hay que tener en cuenta un aspecto importante, y es que *el modelo de mejor IC no es necesariamente el de mejor retorno neto*. El IC mide la calidad del *ranking* antes de costes y de construcción de cartera. El retorno neto depende además del *turnover*, de los costes de transacción, de la neutralización y del dimensionado de posiciones. Un modelo puede tener un IC algo superior y, aun así, dar una señal más inestable, con mayor *turnover*, que se coma todo el margen en costes. Esta separación entre IC y Sharpe neto es la que lleva a distinguir con claridad dos preguntas en la memoria: *¿qué modelo predice mejor?* (la *ladder*, Parte I) y *¿de dónde viene el retorno neto?* (la atribución de construcción de cartera, Parte II, capítulo 6).

4.6. Auditoría anti-leakage

La conclusión central del trabajo es negativa: el Stockformer no genera señal predictiva sobre el S&P 500 (su IC es $\approx -0,003$). Un resultado negativo solo es defendible si se descarta que sea un artefacto, es decir, un fallo de alineación, una fuga de información o un error de procesamiento. Por eso, antes de comparar nada, se pasa una auditoría que comprueba seis invariantes. Cinco se cumplen sin problemas. La sexta detecta una fuga, pero *a favor* del modelo complejo, y se deja a propósito (5/6):

1. **Etiqueta bien definida:** la etiqueta de cada acción y fecha es el retorno del día siguiente $\text{Close}_{t+1}/\text{Close}_t - 1$, comprobado contra los precios originales.
2. **Etiqueta coherente:** la matriz de etiquetas que usa el modelo coincide, valor a valor, con la de referencia.
3. **Buffer de retardos bien aplicado:** la primera variable de cierre rezagado mantiene el orden transversal del cociente $\text{Close}_t/\text{Close}_{t-1}$ (la estandarización no altera el orden), señal de que el desfase de 60 filas está bien hecho.
4. **Pasado y futuro separados:** al formar las secuencias del Stockformer, la ventana de etiquetas Y es siempre posterior a la de entrada X ; no hay solapamiento temporal.

5. **Estandarización en la dirección correcta:** el *z-score* se aplica entre las acciones de una misma fecha, no a lo largo del tiempo (esto último filtraría información futura); cada fila tiene media ≈ 0 y desviación ≈ 1 .
6. **Grafo de relaciones:** el grafo de correlación entre acciones se construye con todo el histórico, incluido el test. Eso da una ventaja al Stockformer. Aun con esa ventaja, su IC es negativo, lo que *refuerza* la conclusión en vez de debilitarla.

Se comprobó además que la rama del Stockformer y la de los modelos tabulares usan el mismo desfase de 60 filas, así que no hay desalineación entre ellas que favorezca a unos modelos sobre otros.

Descomposición *wavelet*. El estado del arte señala la transformada *wavelet* del Stockformer (capítulo 3) como posible fuente de fuga, así que también se revisó. La transformada se aplica sobre cada ventana ya recortada, nunca sobre la serie entera, de modo que al descomponer la *entrada* solo se reordena información anterior al instante de predicción. La descomposición de la *etiqueta* (Y_L, Y_H), que sí mezclaría pasos futuros, se calcula pero no se usa como objetivo: los cabezales se entrenan contra el retorno y el signo crudos. Por tanto no entra fuga ni en el entrenamiento ni en el IC.

Esto respalda toda la Parte I. El IC $\approx -0,003$ del Stockformer es un resultado real, no un error. La complejidad de la arquitectura no añade poder predictivo en un mercado eficiente como el S&P 500, como predicen la hipótesis *simpler-is-better* (sección 4.4) y la literatura *shallow-beats-deep* [2], y esa afirmación se apoya en datos auditados y limpios.

Capítulo 5

Parte I: ¿Transfiere Stockformer?

Esta parte responde a la primera pregunta de investigación. ¿Transfiere Stockformer (un modelo de selección de acciones basado en *wavelets*, *transformers* y grafos de relaciones, calibrado sobre acciones chinas A-shares) al universo del S&P 500? La respuesta, anticipada en la introducción, es negativa. Lo que aporta este trabajo está en cómo se obtiene. En vez de comparar Stockformer contra un único rival, se sitúa dentro de una *complexity ladder* (escalera de complejidad) que ordena los modelos modelos arbitrarios de cero parámetros hasta la red de aproximadamente un millón de parámetros.

5.1. Resultados de la complexity ladder

La escalera de complejidad evalúa, sobre un mismo panel del S&P 500 y un mismo *harness* de evaluación, una familia de modelos ordenada por número de parámetros y capacidad representacional. El procedimiento es el mismo para todos. Las predicciones se convierten en un *rank* transversal diario, se calcula el coeficiente de información de rangos (*rank IC*) sobre 250 días de evaluación y, en paralelo, se construye una cartera *long-short* para medir el Sharpe asociado. La métrica central es el IC medio, que mide la correlación entre la señal predicha y el retorno realizado. Un IC positivo y estable es condición necesaria para que un modelo aporte señal. La Tabla 5.1 recoge los resultados.

La escalera se recorre de abajo arriba. En el peldaño cero (*sanity checks*) están los controles sin parámetros entrenables, la cartera nula (**zero**), el *momentum* y la *reversal*. Sirven para calibrar qué valor de IC es indistinguible del ruido en este panel. El *momentum* obtiene un IC de $-0,0128$ ($t = -1,06$, $p = 0,29$) y la *reversal* un IC de $+0,0126$ ($t = 1,06$, $p = 0,29$); ambos son simétricos, no significativos y, en la práctica, ruido. Esa simetría fija una banda de $\pm 0,013$ aproximadamente como magnitud de lo que el azar produce sobre 250 días.

En el primer peldaño (modelos lineales) está el mejor modelo de toda la escalera. El Lasso, con apenas 5 parámetros efectivos tras la regularización, alcanza un IC de $+0,0238$ y, relevante para la Parte II, el mayor Sharpe *long-short* de la tabla en este *split*, de $+0,91$ (el único otro positivo es el de LightGBM, $+0,21$), con un retorno anualizado del $+27,4\%$. Esta última cifra sale de un único *split* de 250 días y es un diagnóstico de la señal, no un resultado de cartera. El resultado de cartera defendible es el *walk-forward* de 215 semanas del Capítulo 6 (Sharpe neto $0,58 \pm 0,49$), no este

Tabla 5.1: Complexity ladder: IC, parámetros y Sharpe por modelo (split único, test del 14 de marzo de 2025 al 12 de marzo de 2026). Todos los modelos se evalúan sobre esos 250 días salvo Stockformer, sobre los 236 días comunes a su corrida (que arranca el 3 de abril de 2025).

Modelo	Familia	Parám.	IC	IC-IR	t	p	Sharpe
zero	sanity	0					
momentum	sanity	0	-0.0128	-0.0670	-1.0589	0.2907	-1.4289
reversal	sanity	0	0.0126	0.0673	1.0635	0.2886	-1.4258
ridge	linear	376	0.0173	0.1064	1.6826	0.0937	-2.8542
lasso	linear	5	0.0238	0.0951	1.5035	0.1340	0.9099
elasticnet	linear	19	0.0157	0.0687	1.0864	0.2784	-0.0607
lightgbm	trees	31	0.0136	0.1110	1.7547	0.0805	0.2062
xgboost	trees	9600	0.0141	0.0926	1.4639	0.1445	-1.8505
stockformer	transformer	1 041 755	-0.0033	-0.0227	-0.3492	0.7273	-4.9526

Sharpe puntual. El Ridge, con 376 parámetros, obtiene un IC de +0,0173 pero un Sharpe de $-2,85$, porque predice direccionalmente algo mejor que el ruido aunque su cartera no es rentable, lo que muestra que IC y Sharpe no son intercambiables. El *elastic net* queda en un IC de +0,0157, intermedio y en línea con el resto de lineales.

En el segundo peldaño (árboles) está LightGBM, con un IC de +0,0136 y un Sharpe de +0,21. Su capacidad efectiva en la escalera es de solo 31 hojas. Aunque se le permitían hasta 300 iteraciones, la parada temprana sobre el conjunto de validación detuvo el *boosting* en la primera, de modo que el *ensemble* se reduce a un único árbol de 31 hojas (el número de hojas por defecto de LightGBM); el *gradient boosting* no llega a construir un *ensemble*, porque no encuentra estructura que añadir más allá del primer árbol. XGBoost (9600 hojas nominales) obtiene un IC de +0,0141 y un Sharpe de $-1,85$. Los árboles no mejoran a los lineales, porque su IC es parecido o inferior al del Lasso pese a tener mucha más capacidad. El salto de tres órdenes de magnitud en parámetros entre LightGBM y XGBoost no da ganancia de IC.

En el peldaño superior está Stockformer, con del orden de un millón de parámetros. Su IC es $\approx -0,003$, negativo y estadísticamente indistinguible de cero. El modelo más complejo de la escalera no supera a un Lasso de cinco parámetros y cae por debajo de la banda de ruido que fijan los controles de sanidad.

La Figura 5.1 resume el resultado. Si el poder predictivo creciera con la capacidad del modelo, cabría esperar una nube de puntos ascendente al moverse hacia la derecha en el eje de parámetros. Lo que se observa es lo contrario, una relación plana en la zona de los modelos simples y un descenso hacia Stockformer. De esta sección podemos concluir que el IC no aumenta con la complejidad. En este panel el mejor modelo es el más simple y el peor es el más expresivo. Este resultado repite, en la selección transversal de acciones, el fenómeno *shallow-beats-deep* que Gu, Kelly y Xiu [2] documentan en el *asset pricing* empírico.




Figura 5.1: IC medio frente a número de parámetros (eje horizontal en escala logarítmica) a lo largo de la *complexity ladder*. Los controles de sanidad sin parámetros entrenables (*momentum* y *reversal*, 0 parámetros) se sitúan por convención en $x = 1$, el extremo izquierdo del eje, al no ser representable el cero en escala logarítmica. La relación es plana o decreciente: el IC no crece con la complejidad y el modelo más complejo (Stockformer) es el peor.

5.2. Significancia estadística

Conviene separar dos preguntas con soporte estadístico distinto. La primera, si Stockformer *transfiere*, tiene respuesta clara y no depende de ningún rival: su IC es $\approx -0,003$, indistinguible de cero, frente a los IC del orden de 0,06 que las arquitecturas profundas obtienen en su mercado de origen (las A-shares chinas). Eso es una no-reproducción inequívoca de su poder predictivo, que se sostiene contra el cero e incluso concediéndole la ventaja del grafo (Sección 4.6). El resultado de la escalera, que el IC no crece con la complejidad y que el modelo más complejo es el peor, es además una afirmación sobre la forma de la relación, cierta en los datos al margen de cualquier p -valor. Ahí no hay nada inconcluyente. La segunda pregunta, si los modelos simples baten a Stockformer de forma *significativa*, es más exigente, y es la que esta sección mide con cuidado para no afirmar más de lo que la evidencia sostiene. La Tabla 5.2 recoge, para cada modelo simple, la diferencia de IC frente a Stockformer, el estadístico t del contraste pareado por día y su p -valor, sobre $n = 236$ días emparejados.

La mayor diferencia corresponde al Lasso, con +0,0319 de IC frente a Stockformer, $t = 1,86$ y un $p = 0,064$. Este p -valor es marginal y no concluyente, porque no llega al umbral convencional de 0,05, de modo que, en sentido estricto, no se puede rechazar la hipótesis nula de igualdad de IC al nivel del 5 %. No se puede decir que el Lasso bate a Stockformer “de forma estadísticamente significativa”. Lo que sí se puede decir es que la dirección del efecto es la misma en toda la escalera. XGBoost supera a Stockformer en +0,0214 ($t = 1,72$, $p = 0,088$), LightGBM en +0,0178 ($t = 1,63$, $p = 0,105$) y Ridge en +0,0187 ($t = 1,42$, $p = 0,157$). Todos los modelos simples baten a Stockformer en

Tabla 5.2: Tests de significancia del IC frente a Stockformer (diferencia de medias, t , p). El contraste usa los $n = 236$ días comunes a ambos modelos, por lo que ΔIC no coincide con la resta directa de los IC medios de la Tabla 5.1 (250 días); el *momentum* se incluye como control de cordura.

Modelo	vs	ΔIC	t	p	n
lasso	stockformer	0.0319	1.8616	0.0639	236
ridge	stockformer	0.0187	1.4215	0.1565	236
elasticnet	stockformer	0.0251	1.5272	0.1281	236
lightgbm	stockformer	0.0178	1.6267	0.1052	236
xgboost	stockformer	0.0214	1.7157	0.0875	236
momentum	stockformer	-0.0093	-0.5822	0.5610	236

IC, todos con el mismo signo, con p -valores del contraste pareado entre 0,06 y 0,16; quedan cerca del umbral convencional, pero ninguno lo cruza. Los contrastes más conservadores de la Tabla 5.3 (test de signos y Wilcoxon) lo confirman, con intervalos de confianza que incluyen el cero en todos los casos: la superioridad es direccional, no significativa. El único control que no bate a Stockformer es el *momentum* ($-0,0093$, $p = 0,561$), que por construcción no es un modelo sino ruido.




Figura 5.2: IC medio por modelo con intervalos de confianza *bootstrap*. El intervalo de Stockformer solapa el cero, lo que es coherente con la ausencia de señal; los modelos simples presentan IC positivos, aunque sus intervalos también rozan el cero, coherente con la significancia marginal de los contrastes.

La Figura 5.2 apoya esta lectura con intervalos de confianza *bootstrap*. El de Stockformer solapa el cero (su señal es indistinguible de la ausencia de señal) y queda en el extremo inferior de la escalera. Los modelos simples están en territorio positivo; sus intervalos también rozan el cero, lo que es justo lo que cabe esperar en un mercado eficiente, donde de precio y volumen públicos no se extrae un IC transversal grande y estable. El punto no es que los modelos simples tengan una señal potente, que no la tienen, sino que el modelo de un millón de parámetros no mejora a los de unos pocos

y es el único modelo con IC negativo.

Esa consistencia direccional no hay que sobreinterpretarla. Que los cinco modelos batan a Stockformer con el mismo signo llama la atención, pero no son cinco evidencias independientes. Los tres lineales son casi colineales y los dos modelos de árboles comparten familia, de modo que el número efectivo de enfoques independientes es del orden de dos, no de cinco. El contraste estadísticamente correcto, que no se ve afectado por esa dependencia entre modelos, es el test de signos temporal, que mide para cada modelo en qué fracción de los días su IC supera al de Stockformer. La Tabla 5.3 lo recoge, junto con el contraste de Wilcoxon, el intervalo de confianza de la diferencia media de IC y el efecto mínimo detectable. El mejor modelo, el Lasso, supera a Stockformer en 130 de 236 días (55,1 %), con un p -valor del test de signos de 0,134 a dos colas y un Wilcoxon de 0,108; el resto queda entre el 50,8 % y el 53,8 %. Ningún modelo cruza el umbral del 5 % por la unidad de observación correcta.

Tabla 5.3: Contraste direccional del rank-IC diario frente a Stockformer (comparación pareada por día, n días comunes). Test de signos temporal (binomial exacto, dos colas), Wilcoxon, intervalo de confianza al 95 % de la diferencia media de IC (Δ IC) y efecto mínimo detectable (MDE) al 80 % de potencia. Ningún modelo cruza 0,05: la superioridad es direccional, no concluyente, y todos los Δ IC observados caen por debajo de su MDE.

Modelo	% días >SF	p signos	p Wilcoxon	Δ IC [IC 95 %]	MDE ₈₀
Ridge	50.8	0.845	0.254	+0,0187 [-0.0072, +0.0446]	0.0369
Lasso	55.1	0.134	0.108	+0,0319 [-0.0019, +0.0657]	0.0481
ElasticNet	53.8	0.268	0.183	+0,0251 [-0.0073, +0.0575]	0.0461
LightGBM	53.8	0.268	0.164	+0,0178 [-0.0038, +0.0393]	0.0306
XGBoost	52.5	0.474	0.200	+0,0214 [-0.0032, +0.0459]	0.0349

Esta no-significancia se entiende mejor a través de la potencia estadística. Con $n = 236$ días y la desviación típica observada de las diferencias de IC, el efecto mínimo detectable (MDE) a una potencia del 80 % y un nivel del 5 % está, según el modelo, entre 0,031 y 0,048 en escala de Δ IC. Todas las diferencias realmente observadas (entre 0,018 y 0,032) caen por debajo de su propio MDE, y el intervalo de confianza al 95 % de cada una incluye el cero. Es decir, el estudio está, por diseño, infradimensionado para resolver efectos del tamaño que este régimen permite. La falta de significancia individual es el reflejo de una señal débil medida sobre una muestra corta y autocorrelacionada, no la ausencia de un efecto. Esta lectura va con el estándar de Harvey, Liu y Zhu [18], que pide estadísticos t del orden de 3 para declarar un factor genuino bajo multiplicidad de contrastes, de modo que, con valores t en torno a 1,5–1,9, toca hablar de evidencia direccional, no de un hallazgo demostrado.

La magnitud observada es la esperable, y eso funciona como control de sanidad. La banda de ruido que fijan los controles ($\pm 0,013$) sirve de referencia, y con ella el Lasso (+0,0238) la supera mientras que Stockformer ($-0,003$) no. Un IC sostenido por encima de 0,05 en un universo *large-cap* tan arbitrado como el S&P 500 sería un indicio de fuga de datos. La auditoría anti-fuga (Sección 4.6) confirma que no hay fuga que favorezca espuriamente al Stockformer; la única detectada, en el grafo, juega a su favor y aun así el IC es negativo. El hallazgo no se apoya, por tanto, en un único p -valor ni

en la unanimidad entre modelos correlacionados, sino en tres lecturas que apuntan a lo mismo: el IC de Stockformer indistinguible de cero, la dirección consistente aunque no concluyente de los modelos simples, y una potencia que sitúa todos los efectos dentro de lo que el régimen permite resolver.

5.3. Modos de fallo de la transferencia

Los resultados de las dos secciones anteriores dejan abierta una pregunta. ¿Por qué no transfiere Stockformer? Para responderla hay que pasar de la constatación empírica a asociar cada observación a un mecanismo causal documentado en la literatura. Hay cuatro modos de fallo que, actuando juntos, explican la pérdida de señal al cruzar de China al S&P 500.

(a) Eficiencia de mercado. Stockformer fue calibrado sobre los índices CSI 300/500, en un mercado dominado por inversores minoristas, donde hay ineficiencias persistentes y patrones de comportamiento que un modelo no lineal puede explotar. El S&P 500 es uno de los mercados más eficientes y arbitrados del mundo, dominado por inversores institucionales. Una señal que captura ineficiencias *retail* en China no tiene nada que explotar en el S&P 500, donde el arbitraje la ha eliminado. Este es el modo de fallo más básico, y va con que ningún modelo de la escalera, ni simple ni profundo, supere un IC de 0,025.

(b) Insuficiencia de la señal OHLCV precio-volumen. Las *features* de Stockformer son básicamente precio-volumen (Alpha360 es OHLCV con *lags*). En un mercado eficiente, la información que hay en el historial de precio y volumen está, en buena medida, ya incorporada al precio. La propia escalera lo confirma. Todos los modelos (lineales y de árboles) ven el mismo panel de ~ 375 variables (Alpha360 más los indicadores técnicos de Alpha158), y los árboles (LightGBM, XGBoost), pese a su mayor capacidad, no superan a los lineales sobre esos mismos insumos; añadir más *features* dentro de la misma familia precio-volumen no recupera el IC. El problema no está en la cantidad de *features*. Está en que la clase de información (OHLCV) no basta a este horizonte en este mercado.

(c) Microestructura. El mercado chino impone límites diarios de fluctuación de precio (*price limits*, típicamente $\pm 10\%$). Estos límites meten una autocorrelación mecánica en los retornos (una acción que toca el límite tiende a continuar al día siguiente) que infla artificialmente el IC alcanzable por un modelo de precio-volumen. El S&P 500 no tiene estos límites, de modo que parte del IC que Stockformer reporta en su mercado de origen no viene de poder predictivo genuino, sino de un artefacto de microestructura que no existe en el mercado de destino.

(d) Dimensionalidad efectiva. En cada corte temporal, el panel da del orden de 400 observaciones transversales efectivas (acciones del universo), frente a los 10^6 parámetros del modelo. Ajustar un modelo de aproximadamente un millón de parámetros sobre una sección transversal tan estrecha tiende al sobreajuste, porque el modelo

tiene capacidad para memorizar ruido idiosincrático en vez de aprender señal generalizable. Esto explica por qué el modelo más complejo es el peor (Sección 5.1) y por qué un Lasso de cinco parámetros, con su fuerte sesgo regularizador, generaliza mejor. La parsimonia ayuda cuando los datos son escasos en la dimensión que importa.

Contraste con los benchmarks reportados. La literatura reciente reporta IC bastante más altos para arquitecturas profundas, pero siempre sobre mercados distintos del S&P 500. Fan y Shen [5] reportan para StockMixer un IC del orden de 0,041 sobre NASDAQ, y Li et al. [4] un IC del orden de 0,064 para MASTER sobre CSI 300. Estas cifras, muy por encima de cualquier valor de la escalera de este trabajo, no contradicen el hallazgo. Lo confirman. Son resultados *in-market* (China u otros universos) que no transfieren al S&P 500, tal como predicen los cuatro modos de fallo anteriores. La transferibilidad cross-market de los modelos de *deep learning* financiero no se puede dar por hecha a partir de su desempeño en el mercado de calibración. Hay que demostrarla empíricamente, y en el caso de Stockformer sobre el S&P 500 la evidencia es que no se produce.

En conjunto, los cuatro modos de fallo no son alternativas excluyentes. Son mecanismos que se suman. Un mercado más eficiente (a) reduce la señal explotable; la señal que queda es de tipo OHLCV insuficiente a este horizonte (b); parte del IC de origen era un artefacto de microestructura que no existe en el destino (c); y la escasez de observaciones transversales frente a la capacidad del modelo (d) convierte cualquier señal débil en sobreajuste. El resultado neto es un $IC \approx -0,003$. Este diagnóstico cierra la Parte I y abre la pregunta siguiente. Si las redes complejas no transfieren, ¿qué sí genera retorno? El Capítulo 6 muestra que la respuesta no está en una arquitectura más compleja, sino en una construcción de cartera cost-aware sobre una señal simple.

Capítulo 6

Parte II: ¿Qué sí funciona?

Esta parte da la vuelta a la pregunta anterior. La respuesta de este trabajo, a partir de su evidencia empírica, tiene dos piezas. La primera, y la principal, es que la palanca está en la construcción de cartera consciente de costes (*cost-aware portfolio construction*) y no en el poder predictivo de la señal. La segunda, es que cuando la señal aprendida se sustituye por un factor simple con contenido real (el momentum residual), el Sharpe robusto del *pipeline* mejora bastante.

Con todo esto se muestra que se puede convertir una señal transversal débil (IC semanal $\approx 0,003$) en una estrategia *long-short market-neutral* semanal con un Sharpe neto de costes de 0,95 sobre una ventana favorable de 52 semanas; pero se muestra también, con la misma extensión y el mismo detalle, que sobre un *walk-forward* de 215 semanas ese Sharpe cae a $0,58 \pm 0,49$. La idea de fondo, que la atribución de construcción cuantifica, es que el retorno neto positivo viene de cómo se construye la cartera (neutralización, penalización de costes, dimensionado por volatilidad) y no de la capacidad de la señal para anticipar retornos. Este resultado encaja con la tesis *simpler-is-better* de la Parte I y con la auditoría anti-fuga (*leakage*) limpia descrita en la metodología.

6.1. De la señal a las posiciones

La estrategia encadena cinco etapas que pasan de las *features* transversales del panel a un libro de posiciones tradeable y evaluado neto de costes. El flujo es el siguiente:

1. El *resampling semanal* remuestrea el panel diario a frecuencia semanal tomando, para cada semana ISO, el último día de cotización como fecha de rebalanceo; la etiqueta es el retorno compuesto hasta el siguiente rebalanceo. La matriz de retornos diarios se conserva para estimar betas móviles y para el dimensionado por volatilidad.
2. La *señal por ensemble de modelos simples* se entrena sobre el panel semanal con un *ensemble* de LightGBM (*gradient boosting*) y *elastic net*. Recoge el hallazgo de la Parte I, que la señal explotable es la que capturan modelos simples y no la red profunda; se combinan un aprendizaje lineal regularizado y uno de árboles *shallow*, en lugar de un único Lasso, para no depender de una sola familia (la

tarea semanal se reentrena sobre datos distintos de la escalera diaria, de modo que el orden de IC por modelo de la Parte I no es directamente trasladable).

3. La *neutralización* residualiza la señal de cada semana por mínimos cuadrados frente a la beta de mercado (y, en el diseño completo, frente a los factores Fama-French de seis dimensiones y los sectores GICS), de modo que la cartera no arrastre apuestas factoriales o sectoriales no deseadas.
4. El *suavizado* pasa la señal neutralizada por una media móvil exponencial (EW-MA) de semivida ≈ 2 semanas, para reducir la rotación entre rebalanceos.
5. La *construcción cost-aware* y el *overlay de régimen* cierran el flujo. Un optimizador convexo resuelve los pesos imponiendo neutralidad de dólar y de beta, una penalización L_1 de costes de transacción, topes por nombre y un objetivo de volatilidad del 10 % anual; por último, un *overlay* de régimen inspirado en el VIX escala la exposición bruta según la volatilidad realizada reciente del mercado.

La decisión de diseño que más pesa es la primera, rebalancear semanalmente en lugar de a diario. La propuesta original lo identifica como “el salto más grande” de Sharpe neto, ya que pasar de diario a semanal recorta la rotación en un factor aproximado de cinco, y como el coste de transacción es lineal en la rotación, ese recorte se traduce casi punto por punto en Sharpe neto. En los experimentos previos de este trabajo, el *long-short* diario perdía dinero una vez descontados los costes; la frecuencia semanal pone la estrategia en territorio neto positivo antes incluso de optimizar la construcción. Esta etapa no añade poder predictivo, no mejora el IC; lo que hace es reducir el coste de obtener la señal que ya existe.

6.2. Construcción de cartera cost-aware

El componente central del *pipeline* es el constructor de cartera, que resuelve, en cada fecha de rebalanceo, un problema de optimización a partir de la señal neutralizada α y de las exposiciones de riesgo. La formulación es la siguiente:

$$\max_w \quad \alpha^\top w - \underbrace{\lambda w^\top \Sigma w}_{\text{opcional, } \lambda=0 \text{ por defecto}} - \frac{\kappa}{10^4} \|w - w_{\text{prev}}\|_1 \quad (6.1)$$

sujeto a las restricciones

$$\mathbf{1}^\top w = 0 \quad (\text{neutralidad de dólar}), \quad (6.2)$$

$$\beta^\top w = 0 \quad (\text{neutralidad de beta}), \quad (6.3)$$

$$\|w\|_1 \leq \text{gross} \quad (\text{apalancamiento bruto, p. ej. 2}), \quad (6.4)$$

$$|w_i| \leq \text{name_cap} \quad \forall i \quad (\text{tope por nombre}). \quad (6.5)$$

Cada término de la función objetivo (6.1) cumple una función precisa. El primer término, $\alpha^\top w$, es el retorno esperado de la cartera bajo la señal. El segundo, $\lambda w^\top \Sigma w$, es una penalización *opcional* del riesgo cuadrático, con Σ estimada mediante el encogimiento (*shrinkage*) de Ledoit-Wolf [14], que regulariza la matriz de covarianzas muestral

(mal condicionada cuando el número de activos es comparable al de observaciones) hacia un objetivo estructurado; en el libro por defecto está desactivada ($\lambda = 0$), y su efecto se evalúa por separado como extensión pre-registrada (Tabla 6.6). El tercer término, la norma L_1 del cambio de posiciones $w - w_{\text{prev}}$ ponderada por el coste κ en puntos básicos, es el término central, porque implementa la regla “operar solo cuando la ventaja supera al coste”. Al penalizar la rotación dentro del problema de optimización, la solución incorpora *no-trade bands* (bandas de no negociación) endógenas, en las que las posiciones cuyo cambio no compensa el coste se quedan donde están. Así se reduce la rotación y se recupera el Sharpe neto a frecuencia semanal.

Las restricciones acotan la cartera en un libro *market-neutral* y controlado en riesgo. La condición (6.2) impone neutralidad de dólar (la suma de pesos largos iguala la de cortos); la (6.3), neutralidad de beta frente al mercado, estimada con una beta móvil sobre una ventana diaria de 60 días; la (6.4) acota el apalancamiento bruto a $\|w\|_1 \leq 2$ (una pata larga y una corta); y la (6.5) limita la concentración por nombre. A la solución del problema se le aplican dos capas posteriores. La primera es un dimensionado por volatilidad que escala el libro para alcanzar un objetivo del 10 % anual, estimado sobre la ventana diaria reciente, con un tope de apalancamiento. La segunda es un *overlay* de régimen que multiplica la exposición bruta por $\{1, 0, 0, 7, 0, 4\}$ según el tercil de volatilidad realizada del mercado en que se sitúe la semana, de modo que baja la exposición en regímenes turbulentos.

Los parámetros del *backtest* usan condiciones realistas para un universo *large-cap*, con un coste de transacción de 8 puntos básicos por lado (*spread* efectivo más impacto y comisiones) y un retardo de un día entre la observación de la señal y la ejecución, para evitar cualquier fuga de información. Se omite a propósito una optimización *end-to-end* (que diferenciaría a través del optimizador) por un criterio de parsimonia, ya que a frecuencia semanal el esquema *predict-then-optimize* captura casi todo el beneficio sin el coste de ingeniería adicional.

6.3. Resultados

La Tabla 6.1 recoge el performance de la estrategia completa sobre la ventana de evaluación de 52 semanas (del 14 de marzo de 2025 al 6 de marzo de 2026, el periodo *out-of-sample* posterior al último reentrenamiento del diseño de ventana única).

Tabla 6.1: Estrategia semanal market-neutral cost-aware (52 semanas, del 14 de marzo de 2025 al 6 de marzo de 2026).

Sem.	Sharpe bruto	Ret. bruto	Sharpe neto	Ret. neto	MaxDD	IC	IC-IR	Turnover
52	1.3933	0.1066	0.9478	0.0700	-0.0475	0.0050	0.0427	0.8099

La estrategia da un Sharpe neto de 0,95, con un Sharpe bruto de 1,39. La diferencia entre ambos, unos 0,45 puntos de Sharpe, es el coste de transacción que la construcción *cost-aware* consigue contener. El retorno anualizado neto es del 7,0 %, con una caída máxima (*max drawdown*) acotada en $-4,75\%$, reducida gracias a la acción conjunta de la neutralidad de beta, el objetivo de volatilidad y el *overlay* de régimen. La rotación media semanal es de 0,81 (sobre un apalancamiento bruto de 2), coherente con el efecto de las *no-trade bands* de la formulación (6.1).




Figura 6.1: Curva de retorno acumulado *out-of-sample* de la estrategia semanal *market-neutral*: serie bruta (gris) frente a serie neta de costes de 8 puntos básicos por lado (roja). La distancia creciente entre ambas curvas es el coste acumulado de la rotación, que la construcción *cost-aware* mantiene bajo control.

La Figura 6.1 muestra la curva de retorno acumulado, con la serie bruta y la neta superpuestas. La separación progresiva entre ambas es el coste de transacción; que la serie neta conserve una pendiente positiva es lo que la construcción *cost-aware* hace posible. Esta cifra aislada no debe sobreinterpretarse. Un Sharpe neto de 0,95 sobre 52 semanas es un resultado favorable, pero una sola ventana anual es una muestra estrecha. La sección siguiente somete este número a una prueba más exigente.

6.4. Robustez walk-forward

Una única ventana de 52 semanas no basta para afirmar que una estrategia es robusta. Para estresar el resultado, el *ensemble* se reentrena de forma periódica (cada 26 semanas) y así se concatenan unas 215 semanas de *out-of-sample*, en torno a cuatro años (de finales de enero de 2022 al 6 de marzo de 2026), en una única curva de equity. En este *walk-forward*, cada predicción se hace con información estrictamente anterior y la estrategia pasa por varios regímenes de mercado en lugar de un solo año favorable. La Tabla 6.2 recoge el resultado.

Tabla 6.2: Robustez walk-forward de la estrategia semanal (215 semanas OOS, de enero de 2022 a marzo de 2026).

Sem. OOS	Sharpe neto	SE	Ret. neto	MaxDD	Sharpe bruto	Turnover	IC
215	0.5795	0.4926	0.0412	-0.1149	1.0455	0.8387	0.0033

La estrategia da un Sharpe neto de 0,95 sobre la ventana favorable de 52 semanas, pero un Sharpe neto de $0,58 \pm 0,49$ sobre el *walk-forward* de 215 semanas, un estimador que no es estadísticamente distinguible de cero. El cociente entre el Sharpe y su error

estándar es de apenas $0,58/0,49 \approx 1,2$, muy por debajo del umbral convencional de significancia, de modo que no se puede rechazar la hipótesis de que el Sharpe poblacional de la estrategia sea nulo. El retorno anualizado neto cae al 4,1 %, la caída máxima se amplía a $-11,5\%$ (más del doble que en la ventana favorable, lo que ilustra el sesgo optimista de evaluar sobre un solo año) y la rotación media se queda en 0,84.

Esta es la lectura defendible. No cabe presentar un Sharpe neto de 0,95 como resultado principal, porque el estimador robusto, sobre cuatro años y múltiples regímenes, es 0,58 con una incertidumbre que abarca el cero. El IC semanal medio de la señal a lo largo de todo el *walk-forward* es de apenas 0,0033, una correlación de rangos prácticamente nula entre la predicción y el retorno realizado. Que una señal tan tenue dé cualquier retorno neto positivo, aun no significativo, es ya informativo, y lleva a la pregunta de la sección siguiente. Si la señal apenas predice, ¿de dónde sale el retorno?

6.5. Atribución de construcción

Esta sección presenta el resultado principal del capítulo. Para aislar de dónde sale el Sharpe neto, se fija el alfa del *walk-forward* (la salida del *ensemble*, generada una sola vez y sin reentrenar) y se la pasa por cuatro variantes de construcción diferentes. Como el predictor no cambia entre variantes, cualquier diferencia en el Sharpe neto se debe a las decisiones de cartera. Conviene precisar que cada variante transforma ese alfa antes de invertirlo (la neutralización por beta y el suavizado reordenan la sección transversal), de modo que la columna IC de la Tabla 6.3 mide la señal ya transformada que alimenta la cartera en cada etapa, no el alfa crudo; por eso el IC baja de 0,0123 a 0,0085 con la neutralización y a 0,0033 con el suavizado, y coincide entre *+cost_aware* y *full* porque el dimensionado por volatilidad y el *overlay* de régimen escalan los pesos sin alterar la ordenación de la señal. La Tabla 6.3 recoge la cadena.

Tabla 6.3: Atribución de construcción: aporte incremental de cada etapa al Sharpe neto.

Variante	Sem.	Sharpe neto	SE	Sharpe bruto	Ret. neto	MaxDD	Turnover	IC
raw_decile	215	0.0452	0.4918	0.8730	-0.0048	-0.2401	3.0662	0.0123
+neutralize	215	-0.3997	0.4922	0.8145	-0.0473	-0.2505	3.1181	0.0085
+cost_aware	215	0.4679	0.4923	0.8944	0.0629	-0.2285	1.6043	0.0033
full	215	0.5795	0.4926	1.0455	0.0412	-0.1149	0.8387	0.0033

La cadena se recorre etapa a etapa, porque su forma es contraintuitiva:

- **raw_decile** (Sharpe neto 0,045). La cartera ingenua de deciles (largo el decil superior de la señal, corto el inferior, equiponderada y rebalanceada cada semana) da un Sharpe neto esencialmente nulo. Su rotación es muy alta (3,07) y los costes se comen el retorno bruto. Este es el punto de partida, y la señal cruda, construida de forma naíf, no genera valor neto.
- **+neutralize** (Sharpe neto $-0,40$). Añadir la neutralización factorial/sectorial *empeora* el Sharpe neto y lo lleva a territorio negativo. Esto puede sorprender, pero es coherente. La neutralización quita exposiciones factoriales que, en esta muestra, sumaban al retorno bruto; depura la señal pero, por sí sola, resta

rentabilidad. La neutralización no es una palanca de retorno, sino una condición de higiene que garantiza un libro *market-neutral* genuino.

- **+cost_aware** (Sharpe neto 0,47). Al introducir el constructor convexo con penalización L_1 de costes y suavizado, el Sharpe neto da un salto de $-0,40$ a $+0,47$. La rotación baja de 3,12 a 1,60. Esta es la palanca, porque la gestión explícita del coste de transacción dentro de la optimización es lo que convierte una cartera neutralizada y deficitaria en una rentable.
- **full** (Sharpe neto 0,58). Añadir el dimensionado por volatilidad y el *overlay* de régimen sube el Sharpe neto hasta 0,58 y, sobre todo, reduce la caída máxima de $-22,9\%$ a $-11,5\%$. Estas capas aportan estabilidad y control de cola más que retorno bruto adicional.




Figura 6.2: Atribución de construcción: Sharpe neto de cada variante con su error estándar. La neutralización (segunda barra) *resta* Sharpe; la construcción *cost-aware* (tercera barra) es la etapa que recupera el resultado y lo lleva a territorio positivo. El alfa crudo del predictor es el mismo en las cuatro variantes; lo que cambia es la construcción de cartera.

La Figura 6.2 muestra esta cadena. La columna de IC de la Tabla 6.3 cae de 0,0123 a 0,0033 a medida que la neutralización y el suavizado depuran la señal, y se queda en torno a 0,003 en las variantes con la construcción *cost-aware*; el mensaje es claro. La palanca del Sharpe neto es la construcción de cartera y no el poder predictivo de la señal. La señal aporta un IC de $\approx 0,003$, prácticamente ruido; lo que separa una cartera deficitaria de una rentable es la neutralización seguida de la gestión explícita de costes. Este resultado enlaza con la Parte I. Si la complejidad del modelo no compra IC, y el IC apenas mueve el retorno, entonces el esfuerzo de ingeniería rinde más puesto en la construcción de cartera que en la arquitectura del predictor. Es la versión cuantitativa, sobre datos propios, de la tesis *simpler-is-better*.

6.6. Ablaciones de datos (Tier B/C)

Si la señal es la limitación, una hipótesis razonable es que enriquecerla con datos nuevos mejore el resultado. La propuesta original identificaba dos familias prioritarias de *features*: fundamentales *point-in-time* (Tier B) y medidas de riesgo de volatilidad realizada (Tier C). Esta sección reporta que ninguna de las dos mejora el Sharpe neto sobre el *walk-forward* de 215 semanas. El estimador robusto de referencia es el Sharpe neto de 0,579 de la estrategia completa (Tabla 6.2).

El Tier B son los fundamentales EDGAR. Se construye un *pipeline point-in-time* a partir de los hechos financieros declarados por cada empresa en los datos XBRL de la SEC, filtrando por la fecha de publicación de cada documento para evitar toda fuga de información, y se derivan *features* de rentabilidad bruta [7], crecimiento de activos, emisión neta y valor compuesto, en línea con el modelo de cinco factores de Fama y French [6]. Concatenadas al conjunto de *features* y reevaluadas en el mismo protocolo, el Sharpe neto baja a 0,195 (frente a 0,579 de referencia), con un retorno anualizado del 1,3 % y una caída máxima que empeora hasta -19,6 %. Los fundamentales no añaden señal explotable a horizonte semanal en este universo *large-cap*; si acaso, meten ruido que degrada la construcción.

El Tier C es la volatilidad realizada / IVOL. La segunda ablación añade *features* de riesgo derivadas solo del precio (volatilidad realizada, volatilidad idiosincrática [IVOL] y beta) motivadas por la anomalía de baja volatilidad [8]. El resultado es igualmente negativo, y el Sharpe neto se queda en 0,220 (frente a 0,579), con un retorno anualizado del 1,4 %. Pese a ser *features* gratuitas, sin fuga y con alta evidencia en la literatura, tampoco mejoran el Sharpe neto de la estrategia.

Estos dos resultados negativos no son un fracaso del trabajo, sino una pieza de evidencia útil. Apoyan, desde el lado de los datos, la misma conclusión que la atribución de construcción mostraba desde el lado del modelo. A horizonte semanal sobre el S&P 500, ni más arquitectura ni más datos mueven el Sharpe neto; lo que lo mueve es la construcción de cartera consciente de costes. Reportarlos con la misma visibilidad que los resultados positivos es, además, una exigencia metodológica. La literatura de *machine learning* financiero tiene muchas mejoras que no sobreviven a una evaluación *out-of-sample* honesta, y publicar los resultados negativos protege contra ese sesgo.

6.7. Los límites de la construcción cost-aware

La atribución de la Sección 6.5 deja también una lectura de diseño. Si en este régimen el valor económico está en la construcción de cartera y no en el predictor, lo razonable para el S&P 500 a horizonte semanal es *invertir* el reparto de capacidad de Stockformer. Este concentra del orden de un millón de parámetros en el predictor y deja la cartera trivial (una ordenación por deciles); aquí, en cambio, el predictor se mantiene parsimonioso a propósito (el *ensemble shallow* de la Parte I) y la sofisticación se pasa a la construcción convexa cost-aware. Queda por ver hasta dónde llega ese reparto, es decir, si la construcción admite todavía alguna pieza aprendida que la mejore o si el libro simple ya agota el margen disponible.

Esta sección lo comprueba en dos pasos. Primero describe el *espacio de construcción*, esto es, cómo depende el Sharpe neto de cada decisión de diseño de la cartera

y cuál es el coste que anula la estrategia. Segundo somete el libro cost-aware a dos intentos de mejora, ambos bajo un protocolo pre-registrado (fijado antes de evaluar el tramo *out-of-sample*, para proteger el análisis contra la selección de ventana), y reporta que ninguno lo bate.

6.7.1. El espacio de construcción y la frontera de costes

Sobre la misma señal *walk-forward* de 215 semanas, se varía una a una las decisiones de construcción manteniendo el resto en su valor por defecto. La Tabla 6.4 recoge la dimensión que más importa para la viabilidad práctica, la sensibilidad al coste de transacción, y la Figura 6.3 resume el barrido completo.

Tabla 6.4: Sensibilidad del Sharpe neto (walk-forward, 215 semanas) al coste de transacción, manteniendo el resto de la construcción en su valor por defecto. El Sharpe neto cruza cero en torno a 20 bps/lado.

Coste (bps/lado)	Sharpe neto	Sharpe bruto	Turnover
0	$+1,04 \pm 0,49$	+1.04	0.84
2	$+0,93 \pm 0,49$	+1.04	0.84
5	$+0,75 \pm 0,49$	+1.04	0.84
8	$+0,58 \pm 0,49$	+1.05	0.84
10	$+0,47 \pm 0,49$	+1.05	0.84
15	$+0,17 \pm 0,49$	+1.05	0.84
20	$-0,12 \pm 0,49$	+1.04	0.84
30	$-0,71 \pm 0,49$	+1.05	0.83




Figura 6.3: Espacio de construcción: Sharpe neto (con error estándar) frente a cada decisión de construcción sobre el *walk-forward* de 215 semanas. La línea vertical marca el valor por defecto. El Sharpe es invariante al objetivo de volatilidad (control de sanidad); el término de riesgo (último panel) no mejora el resultado.

La lectura es directa. El Sharpe neto decae de forma monótona con el coste: +1,04 sin costes, +0,58 al coste asumido de 8 bps por lado, y cruza cero entre 15 y 20 bps por lado. Esa frontera de *break-even*, en torno a 20 bps por lado, mide la fragilidad de la estrategia. El barrido re-tarifa la *misma* cartera a cada nivel de coste sin reoptimizar la penalización de rotación, que se queda constante en 0,84; una construcción que internalizara un coste de 20 bps operaría menos, de modo que el *break-even* real es algo más favorable y ese umbral debe leerse como cota pesimista. Hay un margen real, pero estrecho, y un mercado con costes de ejecución por encima de ese umbral lo elimina. El resto de parámetros confirma que el resultado es robusto en una región amplia (el Sharpe se mantiene entre 0,3 y 0,8 para valores razonables de exposición bruta, concentración y suavizado) y aporta un control de sanidad. El Sharpe neto es invariante al objetivo de volatilidad, como debe ser, porque el dimensionado escala el libro de forma uniforme sin tocar su razón de Sharpe. Además, el punto de operación por defecto no es el de máximo Sharpe del barrido; se fijó a priori y no se ha reajustado a posteriori para inflar la cifra.

6.7.2. ¿Se puede mejorar el libro simple? Dos pruebas pre-registradas

El libro cost-aware simple da un Sharpe neto robusto de 0,58. La pregunta natural es si una pieza aprendida puede mejorarlo. Se prueban dos extensiones, ambas pre-registradas con su criterio de éxito antes de mirar los resultados.

La primera es un blend de aprendices condicionado por régimen. El *ensemble* combina LightGBM y ElasticNet con un peso fijo de 0,5/0,5; aquí ese peso se condiciona al régimen de volatilidad (tres grados de libertad, fijados sobre la validación interna del tramo de entrenamiento). En la Tabla 6.5 se ve el resultado: el blend por régimen *no* bate al constante (Sharpe 0,16 frente a 0,58). La diferencia es inferior a un error estándar, por lo que, según el criterio de éxito fijado de antemano (mejora solo si el Sharpe neto supera al constante en más de 1 SE, con $SE \approx 0,49$), el resultado se clasifica como nulo, el desenlace que el pre-registro veía como más probable. El óptimo de la validación se redujo a ElasticNet puro en los tres regímenes, y ese predictor, con un IC casi idéntico, construye una cartera peor, ya que el promedio fijo 0,5/0,5 es más robusto que la combinación ajustada.

Tabla 6.5: Blend constante frente a blend condicionado por régimen, sobre el mismo walk-forward de 215 semanas y la misma construcción *full cost-aware*. Peso del LightGBM por régimen (resto, ElasticNet): low = 0,0, normal = 0,0, high = 0,0. La diferencia de Sharpe es inferior a 1 SE; según el criterio de éxito pre-registrado ($> 1 SE$), el resultado es nulo.

Variante	IC medio	Sharpe neto	MaxDD	Turnover
Blend constante (0,5/0,5)	+0.0033	+0,58 $\pm$ 0,49	-11.5 %	0.84
Blend por régimen	+0.0032	+0,16 $\pm$ 0,49	-14.4 %	0.83

La segunda es un término de riesgo con covarianza *shrinkage*. El optimizador admite un término de aversión al riesgo $\lambda w^\top \Sigma w$ con una covarianza de Ledoit-Wolf estimada sobre la ventana diaria. La Tabla 6.6 barre λ , y el mejor valor reduce la caída máxima

en apenas 0,6 puntos (de $-11,5\%$ a $-10,9\%$, por debajo del umbral de relevancia pre-registrado) sin tocar el Sharpe, y valores mayores empeoran ambos, porque la minimización de varianza acaba compitiendo con el alfa. El término de riesgo tampoco mejora el libro.

Tabla 6.6: Término de riesgo (covarianza Ledoit-Wolf) en el optimizador cost-aware: Sharpe neto y MaxDD por aversión al riesgo λ (walk-forward, 215 semanas). $\lambda = 0$ es el *baseline*. Resultado: no distinguible de cero (< 1 SE), por debajo del listón de éxito pre-registrado.

λ	Sharpe neto	MaxDD	Turnover
0	$+0,58 \pm 0,49$	-11.5 %	0.84
100	$+0,58 \pm 0,49$	-10.9 %	0.85
1000	$+0,53 \pm 0,49$	-12.9 %	0.91
10000	$+0,41 \pm 0,49$	-20.7 %	1.55
100000	$-0,20 \pm 0,49$	-42.9 %	3.23
1000000	$-0,74 \pm 0,49$	-16.3 %	1.01

6.7.3. El principio simpler-is-better en las dos capas

Los resultados de esta parte completan, desde el lado de la construcción, lo que la Parte I mostró desde el lado del modelo. Se ha buscado mejorar el resultado por tres vías independientes: más capacidad y más datos (Parte I y ablaciones de datos), un blend aprendido condicionado por régimen, y un término de riesgo explícito. Ninguna bate al *pipeline* cost-aware simple. La contribución constructiva es, por tanto, una demostración, sobre datos propios y con un protocolo pre-registrado, de que en este régimen el reparto correcto de capacidad pone la inteligencia en la construcción, y de que esa construcción, una vez es cost-aware, no se mejora con sofisticación añadida. El principio *simpler-is-better* rige la elección del predictor y también la de la cartera.

6.8. ¿Dónde reside el contenido predictivo de la señal?

Las secciones anteriores mantuvieron fijo el alfa del predictor y mostraron que la palanca del Sharpe está en la construcción. Pero esa señal era la del *ensemble* aprendido, cuyo IC semanal es de apenas 0,003. La pregunta es si ese IC casi nulo es una propiedad del régimen o de la señal concreta que se eligió. Un modelo entrenado sobre Alpha360/Alpha158 puede estar diluyendo una estructura de factores que sí existe. Como muestra la Tabla 6.7, un factor de momentum residual calculado de forma directa da un IC del orden de 0,02, mientras que el *ensemble* sobre la misma ventana se queda en $\approx 0,001$. Esta última sección comprueba si un factor simple, definido a priori, aporta una señal con contenido real que la construcción cost-aware pueda explotar.

Para ello se hace una búsqueda disciplinada, pre-registrada para acotar el sobreajuste de *backtest* que documenta Prado [13]: una lista cerrada de factores establecidos (reversal de corto plazo, momentum, calidad y valor), cada uno construido sin fuga de información y evaluado con la *misma* construcción cost-aware y el *mismo* protocolo

walk-forward del capítulo. Para estresar el resultado y disponer de más datos, la evaluación se amplía a una ventana de 311 semanas fuera de muestra (del 27 de marzo de 2020 al 6 de marzo de 2026; ventana inicial de entrenamiento de ~ 104 semanas) que incluye el *momentum-crash* de 2021 [16], con un *holdout* final de 104 semanas reservado (del 15 de marzo de 2024 al 6 de marzo de 2026). El conjunto de candidatos, los factores clásicos de esta sección y las señales adicionales de la Sección 6.8.1, se fijó antes de mirar el *holdout*. Como se contrastan muchas señales, ningún ganador se declara por su IC dentro de muestra. La selección se hace por el t de Newey-West del retorno neto sobre el periodo completo (con el listón de significancia que recomienda Harvey, Liu y Zhu [18]) y por la coherencia económica del factor; el *holdout* reservado no se usa para elegir, sino solo para confirmar a posteriori que el resultado mantiene el signo y no es un artefacto de ventana. La Tabla 6.7 recoge esta primera tanda.

Tabla 6.7: Búsqueda de señal para RQ2 sobre la misma ventana *walk-forward* de 311 semanas (2020–2026, incluye el *momentum-crash* de 2021; *holdout*: últimas 104 semanas). Misma construcción *cost-aware* (coste 8 bps/lado) para todas las señales. El reversal no aporta ni en bruto (Sharpe bruto prácticamente nulo) y los fundamentales no aportan; el momentum residual es la única señal con IC e *holdout* positivos, y su combinación con el *ensemble* da el mejor Sharpe neto. La columna *Holdout* es el Sharpe neto anualizado sobre las 104 semanas reservadas.

Señal	Sharpe neto	t_{NW}	<i>Holdout</i>	Turnover	IC
Ensemble ML (base)	+0,38	+0,95	+0,20	0.82	+0,0009
Reversal 1 sem. (vol-esc.)	−0,66	−1,73	−1,67	1.15	+0,0138
Calidad (fundamentales)	−0,41	−1,17	−1,07	0.26	−0,0032
Momentum residual	+0,50	+1,35	+0,46	0.23	+0,0212
Ensemble + mom. residual	+0,72	+1,82	+0,55	0.43	+0,0204

Antes de leer la tabla, un matiz sobre la propia base. Sobre esta ventana más larga y exigente, el *ensemble* de las secciones anteriores da un Sharpe neto de solo 0,38 (frente al 0,58 del *walk-forward* de 215 semanas), porque parte de aquel 0,58 venía de que la ventana posterior a 2022 era favorable. La cifra defendible de la base, sobre seis años con el *crash* de 2021 dentro, es 0,38, con un t de 0,95.

Sobre esa base, la búsqueda deja un mensaje claro:

- El reversal de corto plazo, el candidato más esperado a priori por su robustez en otros mercados [19], *pierde* en el S&P 500 *large-cap*, con un Sharpe neto de −0,66 y un Sharpe bruto prácticamente nulo, pese a un IC de *ranking* positivo. La aparente discrepancia con la reversión a un día que retiene el Lasso en la Parte I se explica por el horizonte y por la distancia entre IC y retorno. Un IC transversal de apenas $\approx 0,014$ no basta para sostener una cartera rentable a la semana. En términos de retorno, los nombres que más se mueven tienden a continuar, no a revertir.
- Los fundamentales (calidad, valor) no mejoran el resultado, en línea con la ablación de la Sección 6.6, donde la calidad, aislada, resta Sharpe.
- El momentum residual (el momentum de los retornos residualizados frente al mercado, en la línea de Blitz, Huij y Martens [20], de menor riesgo de *crash* que

el momentum simple) es la única señal con un IC genuino (0,021) y un *holdout* positivo. Por sí solo da un Sharpe neto de 0,50; combinado con el *ensemble* (suma de ambas señales estandarizadas), sube el Sharpe neto a 0,72 ($t = 1,82$), con un *holdout* de +0,55 y una rotación contenida (0,43).




Figura 6.4: Retorno acumulado del *pipeline* momentum residual más *ensemble* sobre la construcción cost-aware (*walk-forward* de 311 semanas, del 27 de marzo de 2020 al 6 de marzo de 2026): serie bruta (gris) frente a serie neta de 8 bps por lado (verde). El Sharpe neto es de 0,72 ($t = 1,82$) e incluye el *momentum-crash* de 2021.

El *pipeline* resultante, momentum residual más *ensemble* sobre la construcción cost-aware, es positivo en cinco de los siete años de la muestra (negativo solo en 2021, el *crash* de momentum, y plano en 2022), con una caída máxima del $-7,4\%$ y un retorno anualizado neto del $4,9\%$. Frente a la base de 0,38 sobre la misma ventana, es una mejora apreciable, y el *holdout* reservado confirma que no es un artefacto de ventana.

La honestidad que recorre el capítulo obliga a no sobrevender el resultado. Con $t = 1,82$, y siendo este el mejor de una búsqueda de varias señales, el Sharpe del *pipeline* no cruza el umbral de significancia una vez ajustado por multiplicidad (véase el cierre de la Sección 6.8.1). Es el techo que el régimen permite con datos públicos. Lo que sí cambia respecto al punto de partida es la *forma* de la respuesta a RQ2. La respuesta deja de ser solo “la construcción” y pasa a tener dos piezas concretas, el momentum residual como señal y la construcción cost-aware que lo explota. Y apoya, una vez más, el principio *simpler-is-better*, porque el factor directo bate a Stockformer y también a la señal aprendida que lo tenía entre sus entradas.

6.8.1. Transferencia modular y banco ampliado

La Parte I mostró que el Stockformer no transfiere como un todo. Queda la pregunta inversa, esto es, si alguna de sus ideas concretas, el grafo de relaciones o la descomposición frecuencial, reducida a una señal simple y causal, aporta algo sobre el predictor *shallow*. La causalidad importa aquí, y el grafo se reconstruye con una

ventana móvil de solo pasado, sin la fuga del grafo sobre todo el histórico que describe la Sección 4.6. Se prueban cinco señales, que cubren los dos componentes que definen al modelo. Del grafo salen tres: pares por correlación (momentum de los vecinos más correlacionados), *lead-lag* direccional (los nombres que anticipan a cada acción, en la línea de la atención espacial asimétrica) y pares por sector (*industry momentum*). De la wavelet salen dos, una por banda: momentum de la tendencia (baja frecuencia) y reversal del residuo (alta frecuencia). A ellas se suma un banco pre-registrado de seis factores establecidos: baja volatilidad idiosincrática [8], *betting-against-beta*, momentum gestionado por volatilidad [17], estacionalidad, proximidad al máximo de 52 semanas y *trend* de series temporales. Todas se evalúan igual, solas y sumadas al *ensemble*, con la misma construcción y el mismo *walk-forward*. La Tabla 6.8 recoge el resultado.

Tabla 6.8: Búsqueda de señal ampliada: señales destiladas de la arquitectura del Stockformer (su grafo en tres formas (correlación, lead-lag direccional y sector) y su wavelet en las dos bandas) y banco pre-registrado de factores establecidos, cada una *sola* y *combinada* con el *ensemble* de *features* (columnas +ens). Misma construcción cost-aware y *walk-forward* de 311 semanas (*holdout*: 104) que la Tabla 6.7. Las columnas *Hold.* son el Sharpe neto anualizado restringido a las 104 semanas de *holdout*. Listón pre-registrado: $t_{NW} > 2$ y *holdout* > 0.

Señal	Sharpe	t_{NW}	<i>Hold.</i>	IC	Sharpe _{+ens}	<i>Hold.</i> _{+ens}
<i>Predictor base</i>						
Ensemble ML (base)	+0,38	+0,95	+0,20	+0,0009	n/a	n/a
<i>Destiladas de la arquitectura del Stockformer</i>						
Grafo: pares por correlación	-0,43	-1,10	+0,20	-0,0172	-0,29	+0,28
Grafo: lead-lag direccional	-0,97	-2,68	-1,27	-0,0034	-0,19	-0,22
Grafo: pares por sector	-0,62	-1,38	-0,97	-0,0142	-0,03	+0,38
Wavelet: tendencia (baja frec.)	+0,29	+0,67	+0,70	+0,0035	+0,21	+0,69
Wavelet: reversal (alta frec.)	-0,50	-1,26	-0,65	+0,0163	+0,10	+0,20
<i>Banco de factores establecidos (pre-registrado)</i>						
Baja vol. idiosincrática (IVOL)	-1,02	-2,41	-0,98	-0,0000	-1,11	-1,19
Betting-against-beta	-0,75	-1,74	+0,61	-0,0070	-0,09	+0,41
Momentum gestionado por vol.	+0,37	+1,01	+0,42	+0,0188	+0,68	+0,63
Proximidad máximo 52 sem.	-0,36	-1,08	-0,21	+0,0116	+0,07	+0,18
Trend / TS-momentum	-0,05	-0,13	+0,24	+0,0101	+0,37	+0,84
Estacionalidad	-0,26	-0,67	-0,56	-0,0004	-0,07	+0,07

La tabla deja cuatro lecturas:

- El grafo no transfiere en ninguna de sus formas. Los pares por correlación son anti-predictivos (Sharpe neto -0,43) y los pares por sector también (-0,62). El *lead-lag* direccional, la variante con más respaldo teórico [21], es el peor de los tres, con un Sharpe de -0,97 y un t de -2,68. En este universo, los nombres que lideran a otros no anticipan su movimiento, lo invierten.
- La wavelet tampoco aporta. La banda de baja frecuencia (tendencia) queda apenas positiva y no bate la base (Sharpe +0,29); la de alta frecuencia (reversal)

pierde dinero pese a un IC de ranking positivo (+0,016). Los dos componentes que definen al Stockformer, su grafo y su descomposición frecuencial, no transfieren contenido al S&P 500 ni enteros (Parte I) ni por piezas.

- Los factores defensivos fallan. La baja volatilidad idiosincrática es el peor candidato de toda la búsqueda (Sharpe $-1,02$, $t = -2,41$); el *betting-against-beta* ($-0,75$), la proximidad al máximo de 52 semanas ($-0,36$) y la estacionalidad ($-0,26$) también restan. En este universo y ventana, ni la baja volatilidad ni la estacionalidad son explotables.
- El momentum es lo único con contenido. El momentum gestionado por volatilidad es la mejor señal del banco, y sumado al *ensemble* da un Sharpe neto de $0,68$ ($t = 1,91$), un *holdout* de $+0,63$ y el IC más alto de la búsqueda ($0,018$), casi la cifra del momentum residual. El *trend* de series temporales deja un *holdout* todavía mayor ($+0,84$). Dos construcciones distintas del momentum dan el mismo Sharpe, en torno a $0,7$, y un *holdout* positivo. La señal que funciona es de familia momentum, y el resultado no depende de cómo se la construya.

Ningún candidato cruza el umbral estricto de $t > 2$, que tampoco cruzaba el momentum residual ($t = 1,82$). Con datos públicos, el techo de este régimen está en un Sharpe en torno a $0,7$.

Conviene cuantificar ese listón. Entre las dos tandas se contrastaron dieciséis señales independientes (cinco factores clásicos, cinco destiladas de la arquitectura y seis del banco pre-registrado), de modo que quedarse con el mejor candidato equivale a tomar el máximo de dieciséis pruebas. Bajo la hipótesis nula de ausencia de señal, el estadístico t con signo más alto de dieciséis contrastes independientes tiene un valor esperado de $\approx 1,8$, prácticamente igual al $t = 1,82$ que da el mejor *pipeline*; la probabilidad de observar por azar un t de al menos $1,82$ en alguna de las dieciséis señales ronda el $0,45$, frente al $0,03$ que sugeriría el contraste aislado. La corrección de Bonferroni al 5% exigiría aquí $t \approx 2,7$ a una cola, próximo al $t \approx 3$ que reclama Harvey, Liu y Zhu [18] para un factor genuino bajo multiplicidad, umbral que ningún candidato se acerca a cruzar. El mejor resultado de la búsqueda debe leerse, por tanto, como evidencia direccional, no como un hallazgo significativo.

Pero la respuesta a RQ2 sí queda definida. El contenido predictivo no está en la arquitectura profunda, que no transfiere ni entera ni por piezas, ni en los factores defensivos. Está en una señal simple de familia momentum, confirmada por dos construcciones independientes y aprovechada por una construcción de cartera consciente del coste.

Capítulo 7

Discusión

Las dos partes del cuerpo empírico (el fracaso de la transferencia de Stockformer en el Capítulo 5 y la construcción de la estrategia semanal *cost-aware* en el Capítulo 6) dan un conjunto de hallazgos que, por separado, podrían leerse como una sucesión de resultados negativos. Aquí se defiende la lectura contraria. Leídos en conjunto, esos hallazgos cuentan una historia coherente sobre dónde está, y dónde no está, el retorno en la selección transversal de acciones *large-cap* a horizonte semanal. La discusión se organiza en cinco partes. La Sección 7.1 explica por qué los modelos simples ganan y conecta el resultado con el fenómeno *shallow-beats-deep* del *asset pricing* empírico. La Sección 7.2 explica por qué ninguna mejora individual recupera el IC, y la razón es que los modos de fallo se componen. La Sección 7.3 trata la honestidad del trabajo, es decir, qué significa y qué no significa el Sharpe neto de 0,95. La Sección 7.4 compara las cifras de este trabajo con los *benchmarks* de la literatura. La Sección 7.5 acota el alcance de las conclusiones.

7.1. Por qué los modelos simples ganan

El resultado central de la Parte I es que el IC no crece con la complejidad del modelo. Un Lasso de cinco parámetros alcanza un IC de +0,0238, LightGBM se queda en +0,0136 y Stockformer, con del orden de un millón de parámetros, cae a $\approx -0,003$. Que el modelo más expresivo sea el peor no es una anomalía del panel de este trabajo. Es, en el dominio de la selección transversal de acciones, un fenómeno bien documentado en la literatura, lo que Rahimikia y Poon [3] llaman *shallow-beats-deep* y que Gu, Kelly y Xiu [2] ya anticipaban al observar que la ganancia del *machine learning* en *asset pricing* viene sobre todo de no linealidades suaves y regularización, no de la profundidad arquitectónica por sí misma.

La explicación es un argumento clásico de sesgo-varianza, aplicado a la geometría del problema. La unidad de información estadística aquí no es la observación diaria, sino la *sección transversal*. En cada corte temporal, el modelo tiene del orden de 400 observaciones transversales efectivas (los nombres del universo) de las que extraer una ordenación. En el *large-cap* estadounidense, esas secciones están además muy correlacionadas en el tiempo, así que el número de muestras *independientes* es todavía menor. Ajustar un modelo de aproximadamente 10^6 parámetros sobre una dimensión efectiva tan estrecha es, en términos de sesgo-varianza, situarse en el régimen de alta varianza. El modelo tiene capacidad de sobra para memorizar el ruido idiosincrático

de cada sección transversal, y eso es lo que hace, de ahí un IC *out-of-sample* negativo. El Lasso está en el extremo opuesto. Su penalización L_1 impone un sesgo fuerte que selecciona apenas cinco coeficientes; sacrifica capacidad expresiva a cambio de una varianza muy baja, y en un régimen con pocos datos en la dimensión que importa, ese canje sale a favor. La parsimonia es aquí la respuesta adecuada a la estructura del problema, no una concesión estética.

Este argumento es específico del *régimen*, no una condena universal de las redes profundas. Stockformer se calibró sobre acciones chinas A-shares, un mercado con ineficiencias *retail* persistentes, no linealidades explotables y, como se discute en la Sección 7.4, artefactos de microestructura que inflan el IC alcanzable; en ese entorno, la capacidad de más encuentra señal que ajustar. El S&P 500 *large-cap* es el régimen inverso, un mercado eficiente y arbitrado donde la señal explotable es tenue y la sección transversal estrecha. En este régimen (señal débil, pocas muestras independientes), el sesgo regularizador de un modelo simple generaliza mejor que la flexibilidad de uno complejo. El resultado de la Parte I no contradice, por tanto, el éxito de las redes profundas en otros dominios; lo enmarca. La profundidad rinde donde hay señal abundante que aprender, y penaliza donde la señal es tenue.

7.2. El efecto compuesto de los modos de fallo

Un lector escéptico podría objetar que el fracaso de Stockformer se debe a un único factor corregible (una pérdida mal elegida, un grafo estático, unas *features* pobres o un protocolo de validación optimista) y que la corrección adecuada recuperaría el IC. El análisis de la Parte I responde a esa objeción, porque la escalera de complejidad muestra que ni más *features* ni más capacidad llevan la señal a territorio positivo robusto. Esta sección explica *por qué*, y la respuesta es que los modos de fallo no actúan en paralelo, sino en serie. Se *componen*.

La idea de fondo es una cadena de cuellos de botella multiplicativos. Cada “arreglo” ataca un modo de fallo distinto: la pérdida de *ranking* alinea la función objetivo con la métrica transversal; el grafo dinámico relaja el supuesto de relaciones estáticas entre nombres; las *features* ricas amplían la información de entrada; el *walk-forward* quita el sesgo de un *split* fijo. Pero cada uno de estos arreglos solo libera el cuello de botella que aborda, y deja intactos los demás. Si la señal explotable es escasa porque el mercado es eficiente (modo a), de nada sirve alinear la pérdida con el *ranking*, porque no hay orden genuino que ordenar mejor. Si la clase de información (OHLCV) no basta a este horizonte (modo b), enriquecer las *features dentro de esa misma clase* no añade señal, como muestra la escalera (los árboles, sobre el mismo panel de ~ 375 variables que los lineales, no los superan). Si parte del IC del mercado de origen era un artefacto de microestructura que no existe en el destino (modo c), ningún cambio arquitectónico puede recuperar una señal que nunca fue transferible. Y si la dimensión transversal efectiva es de ~ 400 frente a 10^6 parámetros (modo d), todo lo anterior se ve amplificado por el sobreajuste.

El producto de cuatro factores, cada uno cercano a cero, es cercano a cero. Esta es la razón estructural por la que ninguna mejora aislada recupera el IC, pues corregir un solo factor de un producto de varios factores próximos a cero no cambia el resultado. El modelo más complejo de la escalera no falla por un defecto puntual de configuración

que un *ablation* bien dirigido pudiera subsanar; falla porque trabaja en un régimen donde varios mecanismos de pérdida de señal actúan a la vez, y cada uno bastaría, por sí solo, para acercar el IC a cero. El patrón de la escalera no es una serie de fracasos independientes. Confirma una hipótesis única, y es que la no transferibilidad de Stockformer al S&P 500 es robusta porque está *sobredeterminada*.

7.3. Honestidad sobre el Sharpe

Esta sección trata el punto metodológico más delicado de la discusión. La estrategia semanal *cost-aware* de la Parte II alcanza un Sharpe neto de 0,95 sobre una ventana de 52 semanas. Es una cifra atractiva, pero no se toma como el titular del trabajo, por una razón sencilla. Un Sharpe de 0,95 medido sobre una única ventana anual es, en el mejor de los casos, un estimador de varianza muy alta, y en el peor, un artefacto de haber elegido una ventana favorable. Una sola realización de 52 semanas no permite distinguir entre habilidad y suerte.

El estimador defendible es el del *walk-forward*. Al reentrenar periódicamente y concatenar 215 semanas de *out-of-sample* (en torno a cuatro años que atraviesan varios regímenes de mercado), el Sharpe neto cae a $0,58 \pm 0,49$. El cociente entre el estimador y su error estándar es de aproximadamente 1,2, muy por debajo del umbral convencional de significancia, así que *no puede rechazarse la hipótesis de que el Sharpe poblacional de la estrategia sea nulo*. La caída máxima, además, se duplica respecto a la ventana favorable, lo que muestra el sesgo optimista de evaluar sobre un solo año. La cifra honesta es $0,58 \pm 0,49$, estadísticamente indistinguible de cero, y no el 0,95 de la ventana favorable.

La Figura 7.1 muestra esta fragilidad. El desempeño se degrada de forma sistemática al pasar de la ventana estrecha al protocolo de cuatro años. No basta con reportar la cifra robusta; hay que explicar además *de dónde viene* el retorno neto positivo, por modesto y no significativo que sea. La atribución de construcción de la Parte II es clara. El IC semanal de la señal a lo largo de todo el *walk-forward* es de apenas 0,0033, una correlación de rangos casi nula. Esa señal débil basta, aun así, para generar un retorno *bruto* apreciable, pues la cartera de deciles cruda rinde un Sharpe bruto de 0,87, y el problema es que los costes de transacción se lo comen. La descomposición etapa a etapa lo confirma. La neutralización factorial, por sí sola, *resta* Sharpe (lo lleva a $-0,40$), y es la construcción *cost-aware* (la gestión explícita del coste de transacción dentro de la optimización) la que *conserva* ese retorno en neto, hasta el entorno de 0,58. La construcción no crea retorno de la nada; es la condición necesaria para conservar el de una señal floja, así que la palanca del Sharpe *neto* es la construcción de cartera y el origen del retorno bruto es la señal, por débil que sea.

Esto plantea una tensión. En los propios datos, el IC y el Sharpe realizado apenas se correlacionan a nivel de señal, pues el *ensemble* base, con un IC semanal en torno a 0,001, sostiene un Sharpe bruto cercano a la unidad, mientras que otras señales con un IC bastante mayor en valor absoluto dan Sharpes nulos o negativos. Esto no invalida la métrica de la Parte I, pero acota su alcance. El rank IC mide poder de ordenación transversal, que es condición necesaria pero no suficiente para el retorno económico, porque este depende además de la construcción y de la estructura de costes. El veredicto de la Parte I, que el IC no crece con la complejidad, se sostiene como




Figura 7.1: Mapa de calor de las métricas de la estrategia a través de las configuraciones de construcción y los protocolos de evaluación. El contraste entre la ventana favorable de 52 semanas y el *walk-forward* de 215 semanas muestra la fragilidad del Sharpe neto de 0,95 frente al estimador robusto de $0,58 \pm 0,49$.

afirmación sobre poder predictivo; traducir ese IC en retorno es lo que estudia la Parte II.

Este IC casi nulo *no* es síntoma de un fallo de implementación. La auditoría anti-fuga (*leakage*) descrita en la metodología verificó que la única fuga detectada (el grafo construido sobre todo el histórico) favorece al modelo complejo, así que la conclusión negativa no puede atribuirse a una ventaja indebida en su contra. Esto es lo que hace que el resultado sea honesto y no un *bug*. Si el IC fuera artificialmente positivo por una fuga, habría un error que corregir; al ser genuinamente nulo incluso concediendo al modelo complejo la única fuga existente, hay un hallazgo que reportar. La literatura de *machine learning* financiero está llena de Sharpes altos que no sobreviven a una evaluación honesta (un sesgo que Prado [13] documenta bajo la etiqueta de sobreajuste de *backtest*), y la defensa frente a ese sesgo es la que aquí se adopta, es decir, reportar el estimador robusto con su incertidumbre, atribuir el retorno a su fuente real y no presentar como descubrimiento lo que es ruido bien construido.

Una búsqueda de señal posterior (Sección 6.8) refuerza esta lectura honesta en lugar de contradecirla. Evaluado sobre una ventana *walk-forward* más larga, de 311 semanas, que incluye el *momentum-crash* de 2021, el propio *ensemble* base cae de 0,58 a 0,38, porque parte de aquel 0,58 era, en efecto, ventana favorable. Sobre esa misma ventana exigente, cambiar la señal aprendida por un factor simple con contenido real, el momentum residual, sube el Sharpe neto del *pipeline* hasta 0,72 con un *t* de 1,82. Es la mejor cifra del trabajo y una respuesta concreta a RQ2, pero sigue sin cruzar el umbral de significancia, y confirma que el techo de este régimen con datos públicos está en el entorno de un Sharpe de 0,7, no más allá.

7.4. Comparación con benchmarks reportados

Las cifras de IC de la escalera de este trabajo (un máximo de +0,0238 para el Lasso) son modestas frente a los *benchmarks* que la literatura reciente reporta para arquitecturas profundas. Fan y Shen [5] comunican para StockMixer un IC del orden de 0,041 sobre NASDAQ, y Li et al. [4] un IC del orden de 0,064 para MASTER sobre CSI 300. A primera vista, esta brecha podría leerse como prueba de que los modelos, o el *harness*, son deficientes. Aquí se defiende lo contrario. Estas cifras no contradicen los hallazgos de este trabajo; los confirman, porque vienen de mercados con una microestructura distinta y *no transfieren* al S&P 500.

Dos consideraciones sostienen esta lectura. La primera es de eficiencia de mercado. El IC de 0,064 de MASTER se obtiene sobre el CSI 300, un mercado dominado por inversores minoristas con ineficiencias persistentes; el de StockMixer, sobre el NASDAQ, un universo más amplio que el de las mega-capitalizaciones del S&P 500. La señal explotable en esos entornos es mayor que en el segmento *large-cap* estadounidense, el más arbitrado del mundo. Esperar que un IC obtenido en China se reproduzca en el S&P 500 es dar por supuesta, sin evidencia, la transferibilidad *cross-market*, que es justo el supuesto que la Parte I refuta.

La segunda consideración afecta a la *ejecutabilidad* del IC reportado. El mercado chino impone límites diarios de fluctuación de precio (*price limits*). Una acción que toca su límite introduce una autocorrelación mecánica en los retornos (tiende a continuar al día siguiente) que infla el IC alcanzable por un modelo de precio-volumen sin que ese

IC sea necesariamente *tradeable*. Cuando la señal querría operar al límite, el mercado está bloqueado y la operación no se ejecuta. Una parte del IC de los *benchmarks* de mercados con límites de precio puede ser, por tanto, un artefacto no ejecutable. El S&P 500 no tiene esos límites, así que un IC medido en él, aunque más bajo, es más representativo de lo que un sistema real podría obtener. La comparación de IC entre mercados con microestructuras distintas es, en consecuencia, una comparación entre regímenes, no una comparación de calidad de modelos en igualdad de condiciones. Hay que leerla, por tanto, con la cautela correspondiente.

7.5. Limitaciones

La interpretación de los resultados se ha hecho con franqueza, y el alcance de las conclusiones se acota con la misma claridad. A continuación se enumeran las limitaciones principales. No son un descargo, son las condiciones de validez de los hallazgos.

Datos públicos y gratuitos. Todo el trabajo se apoya en fuentes de datos públicas y sin coste: OHLCV, fundamentales *point-in-time* de la SEC y medidas de riesgo derivadas del precio. No se dispone de los conjuntos de datos propietarios (microdatos de *order book*, datos alternativos, estimaciones de analistas en tiempo real) con los que operan los fondos cuantitativos profesionales. Es posible que parte de la señal que no aparece en este panel esté en esas fuentes; estos resultados acotan lo alcanzable con datos públicos, no lo alcanzable en términos absolutos.

Universo large-cap y horizonte semanal. Tanto la no transferibilidad de Stockformer como la atribución de construcción se establecen sobre el S&P 500, grandes capitalizaciones, a frecuencia de rebalanceo semanal. Las dos elecciones definen el régimen más eficiente del espacio de posibilidades. No puede darse por hecho que las mismas conclusiones se mantengan en *small-* o *mid-cap*, en mercados emergentes o a horizontes intradía, donde la señal explotable y la estructura del problema son distintas.

Ausencia de volatilidad implícita por acción. El *overlay* de régimen y las medidas de riesgo se construyen a partir de la volatilidad *realizada* derivada del precio, con el VIX como índice agregado de volatilidad implícita del mercado. Lo que no se incorpora es la volatilidad implícita *por acción* (*option-implied* a nivel de *ticker*), que podría aportar una señal prospectiva de riesgo idiosincrásico de la que el diseño actual carece. Es una limitación de datos, no de método, y una de las vías más claras de trabajo futuro.

Profundidad temporal y un solo país. La evidencia cubre del orden de ocho años y un único mercado nacional. Ocho años contienen pocos regímenes independientes (de ahí la incertidumbre de $\pm 0,49$ en el Sharpe *walk-forward*), y un solo país impide separar lo que es propio del S&P 500 de lo que sería un fenómeno general de los mercados eficientes. Un estudio sobre varios países y ventanas más largas robustecería, o matizaría, las conclusiones.

Sesgo de supervivencia. El universo lo forman los componentes *actuales* del S&P 500 con cobertura completa de precios en la ventana, descargados de Yahoo Finance; no se reconstruye la composición *point-in-time* del índice ni se incluyen los valores excluidos a lo largo del periodo (*delistings*, fusiones, quiebras). Esto introduce un sesgo de supervivencia que afecta sobre todo a la pata corta de la estrategia, porque las peores acciones de cada momento, que una reconstrucción *point-in-time* sí incluiría, quedan sub-representadas. Es la limitación de datos más importante para la cartera de la Parte II.

Sin control de reproducción en el mercado de origen. La no transferibilidad se establece evaluando esta implementación del Stockformer en el S&P 500, pero no se ha reproducido el IC que el modelo original reporta en los índices chinos CSI 300/500 con la misma implementación. Sin ese control, “no transfiere” no puede separarse del todo de “esta reimplementación no reproduce el resultado de origen”, aunque la auditoría anti-fuga y la consistencia del *harness* acotan ese riesgo. Reproducir el IC en el mercado chino es el control más directo que queda pendiente.

Una sola semilla y pérdida adaptada. El Stockformer evaluado corresponde a una única ejecución, sin varianza por semilla, y a una pérdida de regresión adaptada (la combinación ListNet+IC+MAE en lugar del MAE original), elegida por alinearse mejor con el *ranking*. El titular de no transferibilidad se apoya, por tanto, sobre una variante y una realización; una ablación con la pérdida original y varias semillas acortaría la incertidumbre, aunque la magnitud del fallo ($IC \approx 0$) y su sobredeterminación hacen poco probable que una semilla distinta lo revierta.

Huecos en la escalera de complejidad. La escalera salta de los árboles potenciados ($\sim 10^4$ parámetros) al Stockformer ($\sim 10^6$) sin un peldaño intermedio de red neuronal superficial. La omisión no es menor, porque en el resultado de Gu, Kelly y Xiu [2] sobre el que se apoya la hipótesis *shallow-beats-deep* el mejor modelo no es un árbol ni un *transformer*, sino una red de tres o cuatro capas (NN3–NN4). El peldaño que pondría a prueba esa hipótesis de la forma más directa, un perceptrón multicapa pequeño evaluado con el mismo *harness*, es justo el que aquí falta. Con un único punto en la cúspide, la evidencia muestra que *este* modelo no transfiere y que el IC no crece en el tramo de los modelos simples, pero no permite confirmar que una red superficial de capacidad intermedia reprodujera el desempeño que Gu, Kelly y Xiu [2] documentan en su panel. Añadir ese peldaño de MLP superficial es el contraste pendiente más informativo de la Parte I y queda como trabajo futuro.

Coste de préstamo de la pata corta. El *backtest* contabiliza *spread*, impacto y comisiones, pero no el coste de préstamo de títulos (*borrow*) de la pata corta, que con una exposición bruta $2\times$ no es despreciable para los nombres más difíciles de tomar prestados. Incluirlo bajaría algo el Sharpe neto, en una magnitud acotada por tratarse de *large-caps* líquidas, donde el *borrow* suele ser barato.

Significancia económica límite. Por último, y de forma coherente con la Sección 7.3, la significancia económica de la estrategia es, honestamente, *límite*. El mejor

pipeline del trabajo (momentum residual más *ensemble* sobre construcción cost-aware) alcanza un Sharpe neto de 0,72 con un t de 1,82 sobre datos públicos *large-cap* y costes realistas, una mejora apreciable sobre la base de 0,38 en la misma ventana, pero un retorno esperado que todavía no se distingue con confianza del cero. El valor del trabajo no está, por tanto, en haber encontrado una estrategia rentable sin lugar a dudas. Está en haber *cuantificado con honestidad* dónde está la palanca del retorno. Esa palanca no está en la arquitectura del modelo ni en más datos. Está en una señal-factor simple (el momentum residual) explotada mediante una construcción de cartera consciente de costes. Esa cuantificación, y la disciplina metodológica que la sostiene, es la aportación de este trabajo.

Capítulo 8

Conclusiones y trabajo futuro

8.1. Conclusiones

Este trabajo se planteó dos preguntas de investigación encadenadas, y cada una de las dos partes de su cuerpo empírico responde a una. La primera (¿transfiere un modelo de *deep learning* financiero calibrado en un mercado a otro mercado estructuralmente distinto?) tiene en el Capítulo 5 una respuesta negativa y clara. Stockformer, una arquitectura de en torno a un millón de parámetros que rinde sobre acciones chinas A-shares, no traslada su capacidad predictiva al S&P 500. Su coeficiente de información *out-of-sample* (*rank IC* transversal, medido día a día) cae a $\approx -0,003$, una correlación de rangos estadísticamente indistinguible de cero, lejos de los IC del orden de 0,06 que las arquitecturas profundas obtienen en las A-shares chinas; y lo bate un Lasso de apenas cinco coeficientes (IC +0,0238). Además, este fracaso no se debe a un fallo puntual de configuración. Como los modos de fallo se acumulan, es poco probable que ninguna corrección aislada (grafos dinámicos, *features* enriquecidas o *walk-forward*) recupere la señal. La no transferibilidad es robusta porque está sobredeterminada.

La segunda pregunta (si no es la capacidad del modelo, ¿qué genera entonces el retorno neto?) tiene en el Capítulo 6 una respuesta concreta. La fuente principal del retorno neto no es la predicción, sino la *construcción de cartera consciente del coste* (*cost-aware*). La atribución etapa a etapa muestra que, con un IC de la señal aprendida de apenas 0,0033, el retorno no viene del poder predictivo, sino de la gestión explícita del coste de transacción dentro de la optimización. La segunda fuente es una búsqueda de señal pre-registrada y validada en *holdout*, que afina esa respuesta. El reversal y los fundamentales no aportan, pero el momentum residual, un factor simple con contenido, combinado con esa construcción sube el Sharpe neto robusto a 0,72 ($t = 1,82$) sobre una ventana *walk-forward* de 311 semanas, frente al 0,38 de la base en la misma ventana (el 0,58 del *walk-forward* de 215 semanas era, en parte, ventana favorable). Aun así, el resultado es modesto, porque con $t = 1,82$ no se puede rechazar la hipótesis de que el Sharpe poblacional sea nulo. La significancia económica es, por tanto, límite.

Tomadas en conjunto, las dos respuestas dan una doble contribución. La primera es empírica, y aporta evidencia documentada de la *no transferibilidad cross-market* de un modelo de *deep learning* financiero, un caso que conecta con el fenómeno *shallow-beats-deep* que documenta Gu, Kelly y Xiu [2], confirmado en datos recientes por Rahimikia y Poon [3], según el cual la ganancia del *machine learning* en *asset pricing* viene de la regularización antes que de la profundidad arquitectónica. La segunda

es metodológica y práctica, y es un *pipeline* reproducible que cuantifica dónde está, y dónde no, la fuente del Sharpe neto. La lección del trabajo es una variante disciplinada del principio *simpler-is-better*. En el régimen más eficiente y arbitrado del espacio de posibilidades (*large-cap* estadounidense, rebalanceo semanal, datos públicos), la parsimonia del modelo es la respuesta correcta a una sección transversal estrecha, y el retorno que sobrevive a los costes sale de una señal-factor simple (el momentum residual) y de cómo se construye la cartera, no de cuánta capacidad tiene el predictor.

Estas conclusiones se apoyan en una jerarquía de evidencia de tres niveles, no en un único contraste. En el primer nivel, el más sólido y que no depende de ningún p -valor, hay dos hechos. El primero es el IC de Stockformer indistinguible de cero, certificado por una auditoría anti-fuga cuya única incidencia es una fuga deliberada a favor del modelo complejo, lo que confirma que el cero es genuino. El segundo es la atribución etapa a etapa sobre la ventana completa de 215 semanas, que sitúa el retorno marginal en la construcción cost-aware. En el segundo nivel, de carácter direccional pero no concluyente, está la superioridad consistente de los modelos simples sobre Stockformer (unánime en signo, pero con p -valores que no cruzan el 5 % y una potencia que, como cuantifica el efecto mínimo detectable, es insuficiente para el tamaño de efecto que el régimen permite) y un Sharpe neto cuyo intervalo de confianza incluye el cero. En el tercer nivel, de contexto, está la calibración de magnitudes frente a la literatura, que sitúa las cifras de este trabajo en la banda esperable para este régimen. La contribución se apoya en el primer nivel; el segundo y el tercero la enmarcan, pero el trabajo no los presenta como pruebas concluyentes.

8.2. Trabajo futuro

Las limitaciones acotadas en el Capítulo 7 marcan a la vez fronteras de validez y direcciones de continuación. Se ordenan por prioridad.

Flujo de inferencia live. La línea más importante, y la que separa este trabajo de un ejercicio de *backtest*, es el paso del retrospectivo histórico a la predicción de posiciones reales. Un sistema operativo necesita tres componentes que el diseño actual aún no integra de extremo a extremo. El primero es la recolección de datos en vivo (OHLCV y fundamentales *point-in-time*) al cierre de cada semana. El segundo es la generación de la cartera objetivo de la semana siguiente a partir de la señal y de la optimización *cost-aware*. El tercero es un protocolo de validación *forward* que contraste las posiciones efectivamente generadas contra los retornos realizados, semana a semana y en tiempo real. Solo esta validación prospectiva, libre por construcción de cualquier sesgo de selección de ventana, puede confirmar o refutar que el Sharpe de $0,58 \pm 0,49$ sobrevive fuera de la muestra histórica. Es el siguiente paso y el de mayor valor.

Señal de sentimiento (GDELT + FinBERT). La atribución de la Parte II mostró que el retorno no viene de la señal de precio-volumen, cuyo IC es casi nulo. Una fuente de información ortogonal podría aportar la señal que el panel OHLCV no contiene. Una vía concreta es construir un indicador de sentimiento de noticias a partir del corpus de eventos de GDELT, procesado con un modelo de lenguaje financiero como FinBERT, y evaluarlo con el mismo *harness* de esta tesis. La disciplina anti-fuga

(*leakage*) y la atribución honesta deben mantenerse, porque el objetivo es medir si el sentimiento añade IC genuino y *tradeable*, no producir otro Sharpe alto irreproducible.

Optimización extremo a extremo y frecuencias mayores. El diseño actual separa predicción y construcción en dos etapas (*predict-then-optimize*). Una optimización diferenciable de extremo a extremo (en la que el objetivo de cartera consciente del coste retroalimenta directamente el entrenamiento del predictor) podría alinear ambas fases y aprovechar mejor la fuente de construcción ya identificada. Esta dirección interesa sobre todo a frecuencias de rebalanceo superiores a la semanal, donde el coste de transacción es más vinculante y, por tanto, la ventaja de internalizarlo en el aprendizaje es mayor.

Meta-aprendizaje y ensembles más ricos. Finalmente, ante la no estacionariedad de los regímenes de mercado (que se ve en el amplio error estándar del Sharpe robusto), cabe explorar esquemas de meta-aprendizaje que adapten el modelo a la deriva de distribución, como DoubleAdapt, así como *ensembles* más ricos que combinen las predicciones de la escalera de complejidad. El criterio debe seguir siendo el de esta tesis, que es subir la capacidad solo donde haya evidencia de señal que aprender, nunca por defecto.

8.3. Implicaciones

Más allá del caso particular del S&P 500, los hallazgos de este trabajo tienen una implicación general para el *machine learning* financiero *cross-market*. La transferencia de un modelo de *deep learning* entre mercados con microestructuras distintas no se resuelve con adaptación incremental (reentrenar, ajustar hiperparámetros, enriquecer las *features* dentro de la misma clase de información). Pide una rearquitectura de fondo. El análisis de la Parte I lo muestra: al componerse los modos de fallo, las correcciones marginales no se acumulan hasta recuperar la señal. Portar un modelo de un mercado minorista e ineficiente a uno *large-cap* eficiente mediante ajustes superficiales supone, sin evidencia, una transferibilidad que el régimen de destino no concede.

La segunda implicación reordena las prioridades de quien busca retorno neto en este régimen. El valor está en la señal-factor y en la construcción, no en la capacidad del modelo (el predictor más complejo de la escalera fue el peor). Por el lado de la señal, lo que aporta contenido es un factor simple y bien elegido, el momentum residual, y no un predictor más expresivo sobre la misma clase de información (la señal aprendida sobre precio-volumen tiene un IC casi nulo). El paso siguiente está en incorporar fuentes genuinamente ortogonales al precio (sentimiento, datos alternativos, volatilidad implícita), y no en añadir expresividad sobre la información ya saturada. Por el lado de la construcción, la gestión explícita del coste de transacción es la única etapa del *pipeline* que añade Sharpe neto positivo. Para el profesional, la lección va en contra del énfasis arquitectónico dominante en la literatura. En el segmento más arbitrado del mercado, el esfuerzo marginal rinde más invertido en mejores datos y en una construcción de cartera consciente de costes que en una arquitectura de predicción más sofisticada. En el plano de la investigación la lección es complementaria, y consiste en reportar el estimador robusto con su incertidumbre, atribuir el retorno a su fuente

real y no presentar como descubrimiento lo que un protocolo limpio revela como ruido bien construido. Esa disciplina, por encima de cualquier cifra concreta, es lo que este trabajo defiende.

Apéndice A

Tablas completas

Este apéndice recoge las versiones de detalle completo de las tablas resumidas en el cuerpo de la memoria. Todos los fragmentos se generan automáticamente a partir de los resultados del estudio, de modo que las cifras quedan ligadas a los datos producidos por el pipeline.

A.1. Complexity ladder completa

La Tabla A.1 muestra todas las métricas evaluadas para cada peldaño de la escalera de complejidad, incluido el Stockformer en la cúspide: IC medio, su desviación, IR, t -estadístico, p -valor, porcentaje de días positivos, intervalo de confianza bootstrap del IC, IC de Pearson, y las métricas de la cartera long-short (Sharpe, retorno anualizado, máximo drawdown, beta, rotación y tiempo de cómputo). Es la evidencia central del resultado “simpler-is-better”, ya que los modelos lineales y de árboles igualan o superan al transformer en IC con una fracción de los parámetros.

Tabla A.1: Resultados completos de la complexity ladder

Modelo	Nivel	Familia	Parám.	IC	IC _{σ}	IC-IR	t	p	% pos.	IC _{inf}	IC _{sup}	IC _P	Sharpe	Ret. anual	MaxDD	Ret. total	β	Turnover	Días	s
zero	L0	sanity	0											0.0000	0.0000	0.0000	0.0000	0.0000	0	0.1000
momentum	L0	sanity	0	-0.0128	0.1909	-0.0670	-1.0589	0.2907	47.6000	-0.0373	0.0105	-0.0102	-1.4289	-0.3094	-0.3625	-0.3073	-0.6429	1.1403	250	0.5000
reversal	L0	sanity	0	0.0126	0.1881	0.0673	1.0635	0.2886	50.0000	-0.0092	0.0366	0.0109	-1.4258	-0.2766	-0.3818	-0.2747	0.3361	2.0495	250	0.5000
ridge	L1	linear	376	0.0173	0.1626	0.1064	1.6826	0.0937	52.8000	-0.0022	0.0378	0.0178	-2.8542	-0.4422	-0.5190	-0.4396	0.1633	3.1481	250	3.0000
lasso	L1	linear	5	0.0238	0.2500	0.0951	1.5035	0.1310	51.2000	-0.0061	0.0554	0.0322	0.9099	-0.2744	-0.1802	-0.2720	1.3147	0.6051	250	3.7000
elastinet	L1	linear	19	0.0157	0.2282	0.0687	1.0864	0.2784	52.0000	-0.0117	0.0446	0.0241	-0.0607	-0.0587	-0.1923	-0.0582	1.1589	1.4177	250	3.7000
lightgbm	L2	trees	31	0.0136	0.1230	0.1110	1.7547	0.0805	50.4000	-0.0009	0.0300	0.0045	0.2062	0.0209	-0.1225	0.0207	0.5717	1.0180	250	4.7000
xgboost	L2	trees	9600	0.0141	0.1523	0.0926	1.4639	0.1445	52.4000	-0.0047	0.0345	0.0166	-1.8505	-0.3582	-0.3622	-0.3560	0.8389	1.9186	250	19.3000
stockformer	L5	transformer	1041755	-0.0033	0.1464	-0.0227	-0.3492	0.7273	48.7288	-0.0223	0.0143	-0.0039	-4.9526	-0.5488	-0.5423	-0.5254	0.2673	3.1197	236	0.0000

A.2. Robustez con datos adicionales

Las dos tablas siguientes documentan los resultados *negativos honestos* de añadir información extra al pipeline semanal. La Tabla A.2 reporta la robustez walk-forward al concatenar fundamentales point-in-time de SEC EDGAR (Tier B); la Tabla A.3 hace lo propio con las variables de realized-vol / IVOL (Tier C). En ambos casos el Sharpe neto out-of-sample no mejora respecto a la línea base (Tabla 6.2), lo que refuerza que el cuello de botella es la señal, no la falta de datos.

Tabla A.2: Robustez walk-forward con fundamentales (Tier B)

Sem. OOS	Sharpe neto	SE	Ret. neto	MaxDD	Sharpe bruto	Turnover	IC
215	0.1954	0.4919	0.0126	-0.1956	0.6009	0.7835	0.0044

Tabla A.3: Robustez walk-forward con realized-vol (Tier C)

Sem. OOS	Sharpe neto	SE	Ret. neto	MaxDD	Sharpe bruto	Turnover	IC
215	0.2198	0.4919	0.0139	-0.1368	0.6901	0.8602	0.0009

A.3. Baseline simple de referencia

Como control de consistencia del *harness*, el *baseline* LightGBM sobre el panel base de ~ 375 variables (Alpha360 más los indicadores técnicos de Alpha158) reproduce exactamente el IC de 0,0136 que ya figura para ese modelo en la Tabla A.1; al tratarse de la misma configuración sobre los mismos insumos, no se reporta por separado.

Bibliografía

- [1] Bo Ma et al. «Stockformer: A price-volume factor stock selection model». En: *arXiv preprint* (2024).
- [2] Shihao Gu, Bryan Kelly y Dacheng Xiu. «Empirical asset pricing via machine learning». En: *The Review of Financial Studies* 33.5 (2020), págs. 2223-2273.
- [3] Eghbal Rahimikia y Ser-Huang Poon. «Machine learning for realised volatility forecasting under cross-market regimes». En: *Journal of Financial Econometrics* (2025). en prensa.
- [4] Tong Li et al. «MASTER: Market-Guided Stock Transformer for Stock Price Forecasting». En: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 38. 1. 2024, págs. 162-170.
- [5] Jinyong Fan y Yanyan Shen. «StockMixer: A Simple yet Strong MLP-based Architecture for Stock Price Forecasting». En: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 38. 8. 2024, págs. 8389-8397.
- [6] Eugene F. Fama y Kenneth R. French. «A five-factor asset pricing model». En: *Journal of Financial Economics* 116.1 (2015), págs. 1-22.
- [7] Robert Novy-Marx. «The other side of value: The gross profitability premium». En: *Journal of Financial Economics* 108.1 (2013), págs. 1-28.
- [8] Andrew Ang et al. «The cross-section of volatility and expected returns». En: *The Journal of Finance* 61.1 (2006), págs. 259-299.
- [9] Stéphane G. Mallat. «A theory for multiresolution signal decomposition: the wavelet representation». En: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 11.7 (1989), págs. 674-693.
- [10] Leonardo F. R. Ribeiro, Pedro H. P. Saverese y Daniel R. Figueiredo. «struc2vec: Learning node representations from structural identity». En: *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2017, págs. 385-394.
- [11] Zhe Cao et al. «Learning to rank: from pairwise approach to listwise approach». En: *Proceedings of the 24th International Conference on Machine Learning*. 2007, págs. 129-136.
- [12] Jan Kwiatkowski y Jarosław A. Chudziak. *On Evaluating Loss Functions for Stock Ranking: An Empirical Analysis With Transformer Model*. 2025. arXiv: [2510.14156](https://arxiv.org/abs/2510.14156) [q-fin.PM].
- [13] Marcos López de Prado. *Advances in Financial Machine Learning*. Hoboken, NJ: John Wiley & Sons, 2018.

- [14] Olivier Ledoit y Michael Wolf. «Honey, I shrunk the sample covariance matrix». En: *The Journal of Portfolio Management* 30.4 (2004), págs. 110-119.
- [15] Nicolae Gârleanu y Lasse Heje Pedersen. «Dynamic trading with predictable returns and transaction costs». En: *The Journal of Finance* 68.6 (2013), págs. 2309-2340.
- [16] Kent Daniel y Tobias J. Moskowitz. «Momentum crashes». En: *Journal of Financial Economics* 122.2 (2016), págs. 221-247.
- [17] Pedro Barroso y Pedro Santa-Clara. «Momentum has its moments». En: *Journal of Financial Economics* 116.1 (2015), págs. 111-120.
- [18] Campbell R. Harvey, Yan Liu y Heqing Zhu. «... and the Cross-Section of Expected Returns». En: *The Review of Financial Studies* 29.1 (2016), págs. 5-68.
- [19] Narasimhan Jegadeesh. «Evidence of predictable behavior of security returns». En: *The Journal of Finance* 45.3 (1990), págs. 881-898.
- [20] David Blitz, Joop Huij y Martin Martens. «Residual momentum». En: *Journal of Empirical Finance* 18.3 (2011), págs. 506-521.
- [21] Andrew W. Lo y A. Craig MacKinlay. «When are contrarian profits due to stock market overreaction?» En: *The Review of Financial Studies* 3.2 (1990), págs. 175-205.